

自己教師あり対照学習を活用した多変量時系列の部分セグメンテーション

加藤 翼^{†,††} 松原 靖子[†] 櫻井 保志[†]

[†] 大阪大学産業科学研究所 〒 567-0047 大阪府茨木市

^{††} 大阪大学大学院情報科学研究科 〒 567-0046 大阪府茨木市

E-mail: [†]{tsubasa.kato.200088,yasuko,yasushi}@sanken.osaka-u.ac.jp

あらまし 物理センサーが生成した時系列データは、多様な状態パターンに変化し、各時刻での状態の識別可能な特徴を持つため、対象物の現在の状態や過去の状態遷移の認識が対象物の行動理解や未来の状態予測に役立つ。本論文では自己教師あり対照学習を活用し、多変量時系列から複数の潜在状態と状態数を自動で特定し、部分時系列の状態遷移の解析手法を提案する。時系列データは局所的なパターンや長期的なパターン、トレンドの変動、ノイズ成分などの複雑な要因が絡むため、普遍的なパターン情報を正しく捉えるためにノイズ除去のモジュールや局所的・長期的なパターンの両方を抽出し、状態数と状態検知を同時に学習する。教師なし学習であるためラベル付きデータや状態数が不要であり、分割窓を用いた部分時系列の特徴抽出を行い、潜在空間上でクラスタリングを行うことで、時間的に離れた同一パターンを同じ状態として認識し、不適切なバイアスの軽減によって異なるパターンの誤検出を抑制した。実データを活用した実験により、提案手法が時系列データの長さに依存せず、既存手法と比較して高精度であること、同一のパターンを検知できること、特徴空間上で視覚的にもパターン変動の情報を保持していること、パターン数が既知の場合の検出と精度の差が見られないことを明らかにした。

キーワード 多変量時系列セグメンテーション, 自己教師あり対照学習, 表現学習, クラスタリング

1 はじめに

時系列データは金融動向や需要予測, 気候モデリング, 自動運転や心拍数, 運動動作, 睡眠などの生体情報に基づく健康管理のアプリケーションなど多くの場面で活用されている。[1–3] これらの時系列データは監視対象の状態変化を捉える豊富な情報を含んでおり、パターン認識やイベント検出, 異常検知, 故障パターンの推定に役立つ。

自動運転データでは、曲がる, 直進, 停止, 加速などの状態パターン情報, 睡眠データでは睡眠の深さや中途覚醒などの睡眠パターン, 工場機械の監視センサでは機械が故障するまでの遷移パターンが存在する。[4–9] これらを正確に認識することで人手を使わないタグ付けやパターン検出, 将来パターンの予測につながる。本研究の目標は与えられた時系列から潜在状態のパターン遷移ができるような特徴表現を獲得することである。

時系列データのパターン認識では個々のデータ点に注目するよりも、より広いコンテキストでデータを理解するアプローチがクラスタリングや分類タスクに有用である。事前にパターンの種類数が未知の場合が多く、十分なラベル付きデータがないことから教師なし学習の研究が進んでいる。パターン検出では各観測点に対して、十分に類似した既存のパターン、もしくは類似したパターンがない場合は新たなパターンとして割り当てるクラスタリングの使用が一般的である。ここでは同じ状態を持つ連続する観測点はシーケンスとして統合する。

図1に示されるように人のモーションダンスの例では、事前

にダンス状態の数や種類を知る必要はなく、結果に基づいてダンス状態を識別してラベル付けを行う。一般的な状態パターンの検出アプローチでは与えられた時系列データをウィンドウサイズごとにエンコードして潜在埋め込み表現を獲得し、その後クラスタリングによって状態検出を行っている。このアプローチではエンコードの段階とクラスタリングの段階を個別に考えられる。しかし以下の3つの主要な課題が残っている。

- ラベル付きデータがない場合、事前に状態の数を知るとは通常難しい。そのため状態の数がわからない場合でも効果的であるべきであり、データから自己学習によって適切な状態の数を学習してラベル付けすることが重要な課題である。

- 最先端のエンコーダーの学習手法は、教師なしコントラスト学習に基づいており、類似サンプル間の類似性の最大化、異なるサンプル間の類似性の最小化が目的である。このアプローチでは、遠隔ウィンドウが異なる状態を持つという理想的な仮定のために、遠隔ウィンドウが同一パターンである場合の誤検出や隣接ウィンドウで異なる状態の場合に同一状態としての検出に陥りやすく、クラスタリングに適した埋め込み空間の形成の堅牢性を確保することが重要な課題である。

- 特徴空間にエンコードする際に、小さな差異によって異なる特徴空間に投射するため、時間軸に沿ったパターンの変化の意味的な情報が消失してしまう。ノイズを除去する必要があることや、局所的な特徴と長期的な特徴をもとに特徴空間上でパターンの視覚的な変化情報の取得が、将来予測や未知の状態特定アプローチにとって重要な情報であり、有益な特徴空間の構築が課題となっている。




図 1 Mocap データセットから左/右腕, 左/右足に対応する 4 次元の時系列データを示している。各状態パターンが人のモーションに対応しており、任意の時間幅で次の状態パターンに遷移している。




図 2 入力時系列はデータ拡張としてフーリエ変換で低周波成分の抽出によってノイズ成分の除去を行い、季節成分とトレンド成分に分割する。その後エンコーダを通して長期的なパターンと局所的なパターンを捉える特徴表現として特徴空間に投射する。その後表現空間上で統計的特徴量が近いパターンが近づき、遠いパターンが遠ざかるように対照学習を行う。

第一の要件を満たすために、学習された表現から状態の数を推定するためにノンパラメトリックベイズ法の DPGMM や密度ベースの HDBSCAN や MeanShift を採用する。第二の要件を満たすために、時系列データの局所的な滑らかさとマルコフ特性のため、大部分の時系列セグメントは簡単なネガティブサンプルと見なされる。これらのセグメントはアンカーとの意味的な違いが大きく、識別に役立つ情報をほとんど提供しないため学習に貢献するのはわずかな勾配だけである。完全に同一ではないアンカーと類似した少数のハードネガティブサンプルを含めることで学習が改善され効率が高まることが示されており、アンカーに似た統計的特徴量やスペクトルエネルギー、主要周波数成分の類似度に応じて、教師なしコントラスト学習の正負のペアを決定する。第三の要件を満たすために、ノイズ除去のために時間的変動と依存関係を維持するために時間領域でのクロッピングと周波数領域でのミキシングを組み合わせたデータ拡張を行い、局所的な特徴と長期的な特徴を捉えるために、任意の部分系列の文脈表現を学習する階層的な構造を採用し、ロス関数において近い観測点は特徴空間で近づくように設計し、

特徴空間上で視覚的な情報が保存されるように学習する。

1.1 本論文の貢献

本論文の貢献をまとめると次の特徴を持つ。

- 状態パターン数が未知の様々なデータに対して、適切なパターン数が学習してパターン検出を行い、適切なパターン数の検出ができることを確認した。
- 教師なしコントラスト学習における似た別状態を正しく識別することを目的とした対照学習手法を提案する。これは考案した類似性に基づく潜在的な正負のペアの決定によって達成され、精度の向上を確認した。
- 時間領域と周波数領域に対するデータ拡張によってノイズ除去を行い、局所的な特徴と長期的な特徴を捉える階層構造や特徴空間上で時間軸に沿って連続的なパターンの変化が捉えられるロス関数の設計を行った。
- 6 つの実世界のデータセットと 6 つのベースラインを用いた広範な実験により、提案手法の効果、スケーラビリティ、汎用性の観点から、従来の手法に対する優位性を実証する。

本研究で提案する自己教師あり対照学習を活用した多変量時系列の部分セグメンテーションのための深層学習フレームワークの概要を図2で示す。

2 関連研究

2.1 時系列の状態パターン分割

状態パターン分割の既存手法には教師あり学習と教師なし学習の手法に分けられるが、本研究ではラベルデータがない状況を想定しているため、教師なし学習の手法にのみ焦点を当てる。さらに状態数の入力が必要な手法と自動で推定する手法がある。

最初のカテゴリの代表的な研究として、TICCはトープリッツ逆共分散に基づく方法である。各クラスターはそのクラスターの典型的な部分系列における異なる観測の依存関係の特徴付ける相関ネットワークによって定義されるが、事前知識に大きく依存し人為的介入が必要である。クラスの数に指定されていない場合にこれらの方法は機能せず、クラス数の推定を行うように修正することは難しい。実データではクラス数が実際に利用可能でないことが多いため、実用性に欠けている。

一方、2番目のカテゴリはより実用的だが、ほとんど研究されていない。AutoPlaitは最小記述長(MDL)を使用してクラス数を推定し、HVGHは変分オートエンコーダ(VAE)と階層的ディリクレ過程(HDP)を組み合わせてクラス数を推定する。AutoPlaitはMDLベースの損失を貪欲に最適化するために複数回の最適化が必要であり、不安定な実行時間と長期時系列は不適切である。HVGHはVAEとHDPの相互学習を複数回行う必要があり、長期時系列は不適切である。

2.2 時系列の表現学習

時系列データの表現学習は長年研究されているが、教師なしの表現学習というより困難な側面に焦点を当てた研究はまだ少ない。表現学習はエンコーダを使用して生データから表現を学習し、それを低次元の埋め込み空間にマッピングする。数多くの時系列表現学習方法が存在するが、セグメント化を下流タスクと考慮する方法は非常に少なく、下流タスクは分類や予測が多いため、データの全体的な類似性に重点を置いている。時系列全体の表現を学習する傾向があり、セグメント化には適していない手法が多い。エンコーダ・デコーダとコントラスト学習のロス関数の設計に焦点を当てた研究が存在する。

これまでの多くの研究は、教師なしの時系列表現学習において再構成誤差を最小化するエンコーダ・デコーダアーキテクチャの開発に集中しており、時系列データに存在する固有の相関関係を利用や時間的な関係の変化に注目しているが、不適切な事前の仮定やデータ拡張手法、多すぎる簡単なネガティブサンプル、下流タスクに十分な情報がない、セグメントの情報を活用できていないことが挙げられる。

2.3 クラスタリング

パターン状態の検出の際にクラスタリングを行う。K-meansやスペクトルクラスタリングなどの既存方法はクラスタ数の入力に事前が必要であり、ここではクラスタ数が未知の場合に對

応可能なクラスタリング手法について焦点を当てる。

X-meansはK-meansの拡張版であり、クラスタ数を自動的に推定する手法である。情報基準(BIC)を用いてクラスタ分割の適切性を評価し、最適なクラスタ数を決定するが、K-meansと同様に球状クラスタを仮定しており、非線形なクラスタ形状への対応力は限定的である。DBSCANは密度ベースのクラスタリング手法で、データポイントの密集度を基準にクラスタを構築する。クラスタ数の指定は必要ないが、パラメータとして近接距離や最小ポイント数を設定する必要がある。MeanShiftはデータの密度最大点(モード)を探索する手法であり、局所的な密度推定に基づきデータポイントを高密度領域へシフトさせる反復プロセスを通じてクラスタを形成する。バンド幅(カーネルのサイズ)を適切に設定する必要がある。大規模データでは計算コストが高くなるという課題がある。ディリクレ過程ガウシアン混合モデルはクラスタ数に対する事前分布としてディリクレ過程を採用したノンパラメトリックベイズ法である。観測データはガウシアン混合モデルから生成され、クラスタ数はデータに応じて自動的に適応される。近似推論には変分推論が用いられ、状態の数やクラスタリングの構造を柔軟に推定できる。

3 問題設定

定義 1. (多変量時系列, MTS) 多変量時系列は複数のセンサーや観測対象から取得した時間的に連続した時系列データである。各時点で複数の観測値を持ち、数学的な定義として

$$\mathbf{X} = \{\mathbf{x}_i\}_{i=1}^T, \quad \mathbf{x}_i \in \mathbb{R}^N, \quad (1)$$

$\mathbf{x}_i$ は i 番目の時間ステップの観測値、パラメータ N は時系列データの次元数、 T は時系列データの長さを表す。時間ステップ i から時間ステップ j までの $\mathbf{X}$ の部分時系列を $\mathbf{X}_{i:j} \in \mathbb{R}^{N \times (j-i)}$ と表す。

定義 2. (状態パターン) 状態パターンは、繰り返されるパターンや類似した統計的特徴を持ち、実世界において潜在的に意味を持つ部分時系列である。

定義 3. (状態シーケンス) 多変量時系列の状態シーケンスは、各観測点 $\mathbf{x}_i$ がどの状態パターンに属するかを示すインデックス s_i を割り当てたシーケンスである。数学的な定義として

$$\mathbf{s} = \{\mathbf{s}_i\}_{i=1}^T, s_i \in \mathcal{S} \quad (2)$$

$\mathcal{S}$ は状態パターンのインデックス集合であり、状態シーケンスと多変量時系列は同じ長さを持つ。

本論文では状態パターンごとに部分時系列への分割可能な多変量時系列 $\mathbf{x}$ を状態パターンの数を推定し、各観測点がどの状態パターンに属するか、与えられた時系列 $\mathbf{x}$ に対応する状態シーケンス $\mathbf{s}$ を決定する精度の良いモデルを提案する。

表1に主な記号と定義を示す。

4 提案モデル

本章では、提案モデルについて述べる。提案手法では訓練

表 1 主な記号と定義

記号	定義
$\mathbf{X}$	時系列データストリーム
$\mathbf{x}_i$	i 番目の時間ステップの観測値
$\mathbf{x}'_i$	周波抽出後の i 番目の時間ステップの観測値
T	時系列データの長さ
N	時系列データの次元数
$\mathbf{X}_{i:j}$	時間ステップ i から時間ステップ j の $\mathbf{X}$ の部分時系列
tc	トレンド成分
sc	季節性成分
$\mathbf{x}''_i$	トレンド成分と季節性成分を結合した i 番目の時間ステップの値
S	状態シーケンス
s_i	i 番目の時間ステップの状態インデックス
$\mathbf{Z}$	特徴空間で表現された時系列データストリーム
$\mathbf{z}_i$	i 番目の時間ステップの潜在値

フェーズと検出フェーズの 2 つのフェーズから構成される。訓練フェーズでは生の時系列データから区別可能な表現を学習するためにエンコーダを学習する。検出フェーズでは学習したエンコードを用いて時系列データの特徴空間に埋め込み表現として変換し、クラスタリングの結果をもとにラベルを割り当て、元の時間点に対しても対応してラベルを付与する。

4.1 ノイズ除去

高周波数および低周波数のノイズを効果的に除去し、全体的なデータ表現を向上させるために、すべての次元にわたる累積エネルギーに基づき、周波数領域からアクティブな周波数を動的に選択して保持する。[10] 信号処理におけるエネルギーは信号の周波数成分の強度を定量化し、低エネルギーは強度と活性の低下を示すことや、ノイズが極端な周波数に集中しやすく、アクティブ周波数は中央範囲に集中する傾向がある。ノイズを除去する過程で重要な情報が欠落しないように連続的な周波数帯域を選択してノイズの除去を行う。図 3 に示すように高速フーリエ変換 (FFT) で時系列データを周波数領域に変換し、低周波成分の抽出を行う。その後逆 FFT を行なって時間領域に戻し、振幅が周波数の数でスケールされるため正規化処理を行う。

$$x'(t) = \text{IRFFT} \left(\begin{cases} \text{FFT}(x), & f \leq \text{trade_off_freq} \\ 0, & f > \text{trade_off_freq} \end{cases}, \frac{\text{trade_off_freq}}{T} \right)$$

trade_off_freq は低周波数のカットオフ点、T は時系列の長さを表す。

4.2 成分分解

時系列データはトレンド、季節性、ノイズ成分に分割することでデータの特性を把握しやすくなる。移動平均を用いてデータをトレンド成分と季節成分に分割する。

- **トレンド成分 (tc):** トレンド成分 $tc \in \mathbb{R}^{N \times P'}$ は、サイズ κ (奇数) の移動平均カーネルを使用して計算する。

$$tc[n, t] = \frac{1}{\kappa} \sum_{i=-(\kappa-1)/2}^{(\kappa-1)/2} x'[n, t + i].$$

- **季節性成分 (sc):** 季節性成分 $sc \in \mathbb{R}^{N \times P'}$ は、トレンド成分 tc を x' からの差で表す。

$$sc = x' - tc.$$

n は次元を表すインデックス、t は時間インデックスである。

$$x'' = \text{concat}(tc, sc)$$

トレンド成分と季節成分を次元方向で結合する。

4.3 デュアル学習

本提案手法では、大域的なパターン情報と局所的なパターン情報を学習するために時系列データ全体に対する機構とスライディングウィンドウ処理を行い部分系列に対する機構の二つを用いてデュアル学習を行う。トレンド成分と季節成分のそれぞれに適用する。

4.3.1 大域的パターン抽出

時系列データ全体を使用し、時系列データの中で各観測点がどのような特徴を持っているかを特徴空間に投射するように学習するモジュールである。時系列データをベクトル表現に変換する TS2Vec を改良したものである。入力時系列に対してランダムクロッピングを行い、学習データの多様性を学習する。入力時系列 $x'' \in \mathbb{R}^{T \times N}$ に対して 2 つのランダムなセグメント $[a_1, b_1]$ および $[a_2, b_2]$ を抽出する:

$$0 < a_1 \leq a_2 \leq b_1 \leq b_2 \leq T$$

この時に大域的な情報を得るために以下の制約を加える。

$$b_1 - a_2 \geq T \cdot \gamma$$

γ は使用する時系列長であり、本研究では 0.8 に設定している。 $\mathbf{x}''_{a_1:a_2}, \mathbf{x}''_{b_1:b_2}$ に対して前結合層で高次元の潜在表現 $\mathbf{z}_{1_{a_1:a_2}}, \mathbf{z}_{2_{b_1:b_2}}$ に変換する。オーバーラップする部分時系列の $[a_2, b_1]$ の潜在表現は一貫性があるように学習するため、対照学習の正のペアとして設定する。異なる時刻や各次元の特徴を学習できるように異なる観測点や異なる時系列を負のペアとして設定する。

i 番目の時系列における観測点 t の時間的な対照損失:

$$\ell_{\text{temp}}^{(i,t)} = -\log \frac{\exp(r_{i,t} \cdot r'_{i,t})}{\sum_{t' \in \Omega} \exp(r_{i,t} \cdot r'_{i,t'}) + \sum_{t' \neq t} \exp(r_{i,t} \cdot r_{i,t'})}$$

i 番目の時系列における観測点 t の各次元間の対照損失:

$$\ell_{\text{inst}}^{(i,t)} = -\log \frac{\exp(r_{i,t} \cdot r'_{i,t})}{\sum_{j=1}^B \exp(r_{i,t} \cdot r'_{j,t}) + \sum_{j \neq i} \exp(r_{i,t} \cdot r_{j,t})}$$

さらに各観測点は時間的に連続であるため、時間的に近い観測点の特徴空間で近くなる平滑さの損失:

$$\ell_{\text{smooth}}^{(i,t)} = (X[t+1, n] - X[t, n])^2$$

時間的な損失は動的なパターン変化を捉え、各次元間の損失は各次元の固有の特性を捉え、特徴空間上で時間的な意味を捉える平滑損失の輪として、大域的な損失は次のように定義される。

$$\mathcal{L}_{\text{global}} = \frac{1}{NT} \sum_i \sum_t (\ell_{\text{temp}}^{(i,t)} + \ell_{\text{inst}}^{(i,t)} + \ell_{\text{smooth}}^{(i,t)})$$




図 3 データ拡張の概要図：時系列データストリームを高速フーリエ変換で周波数領域に変換し、低周波成分抽出を行い、逆フーリエ変換を行って時間領域に変換する。これによってノイズ成分が除去され、時系列が滑らかとなり、ノイズによる局所的なパターンの誤検出を抑制している。

4.3.2 局所的パターン抽出




図 4 局所的パターン抽出の概要図：時系列をスライディングウィンドウで分割し、それぞれで統計的特徴量を計算し、近いものを正のペアに、遠いものを負のペアにしてそれぞれ $\mathcal{L}_{\text{positive}}$, $\mathcal{L}_{\text{negative}}$ を計算し、局所的なパターンを学習する。

設定されたウィンドウサイズとステップ幅をもとに元の時系列データをスライディングウィンドウ処理をする。これにより時系列の分割し、部分時系列として局所的な特徴を捉える。

$$\text{ウィンドウの個数} = \left\lfloor \frac{\text{時系列の長さ} - \text{ウィンドウサイズ}}{\text{ステップ幅}} \right\rfloor + 1$$

図 4 に示すように各ウィンドウごとに平均値、分布やデータの変動を表す標準偏差、周期性の強さや安定性を表すスペクトルエネルギー、主要なデータ周期を表す主要周波数成分の 4 つの統計的特徴量を算出する。この後、基準となるウィンドウに対して統計的特徴量が近いウィンドウを正のペア、遠いウィンドウを負のペアとして設定し、時間的に離れた局所的なパターンを同一の状態パターンであると学習するように促進している。基準となるウィンドウは一様分布からランダムに抽出される。

$$\mathcal{L}_{\text{positive}} = \frac{2}{M \cdot v} \sum_{k=1}^M \sum_{j=1}^v -\log \left(\sigma \left(f_{\theta}(o_i)^{\top} f_{\theta}(o_j) \right) \right)$$

$$\mathcal{L}_{\text{negative}} = \frac{2}{M \cdot v} \sum_{k=1}^M \sum_{j=1}^v -\log \left(\sigma \left(-f_{\theta}(o_i)^{\top} f_{\theta}(o_k) \right) \right)$$

$$\mathcal{L}_{\text{local}} = \mathcal{L}_{\text{positive}} + \mathcal{L}_{\text{negative}}$$

o_i は基準となるウィンドウ, o_j は正のペアウィンドウ, o_k は負のペアウィンドウである。特徴表現へ変換した各ウィンドウの類似性は内積で計算される。

最終的にデュアル学習の損失関数は以下のようになる。

$$\mathcal{L}_{\text{dual}} = \mathcal{L}_{\text{global}} + \mathcal{L}_{\text{local}}$$

4.4 状態パターン検出アルゴリズム

図 5 に示すように、局所パターン抽出と同様に時系列データをスライディングウィンドウで部分時系列として分割した後、学習されたエンコーダを用いて特徴空間に変換し、低次元の特徴空間内で状態パターンのクラスタ構造を識別し、元の観測点にクラスタリングラベルを割り当てる。各観測点は複数のラベルを受け取るため、最終的に各観測点に割り当てられるラベルは、最多で割り当てられたラベルに基づいて決定され、潜在的に誤ったポイントラベルの少数を排除することができる。

5 評価実験

本論文では、提案手法の有効性を検証するため、実データを用いた実験を行った。本章では以下の項目について検証する。

- Q1 状態シーケンスの推定に対する提案手法の有効性
- Q2 提案手法のロス関数設計の有効性
- Q3 提案手法の特徴空間におけるパターン情報保持の有効性
- Q4 状態数既知の場合や一括推論との有効性

5.1 実験設定

5.1.1 データセット

提案手法の有効性を検証するために、5 つの実世界のデータセットと 1 つの合成データセットで実験する。これらのデータセットの統計情報は表 1 に示す。人間の日常動作、運動スポーツ動作、医療や昆虫の監視、電力需要データなど様々な実世界の状態を表すデータセットを選択した。なお、時系列の変化点検出の評価実験に使用されるいくつかのデータセットは状態検出に必要な各観測における状態ラベル情報が欠如しているため、部分時系列のセグメンテーションの評価には適していない。




図 5 検出アルゴリズムの概要図：時系列をスライディングウィンドウで分割してエンコーダによって特徴表現に変換した後、クラスタリングを行い、各ウィンドウに検出した状態インデックス割り当てを行う。その後各観測点に複数の状態インデックス割り当てが行われているため、最多のインデックスを最終的な状態パターンとする。

表 2 データセット詳細

データセット	状態数	次元数	データ長 (k)	データ数	分割数	各状態長 (k)
合成データ	5	4	9.3~23.7	100	18~28	0.1~3.9
MoCap	4~8	4	4.6~10.6	9	6~11	0.4~2.0
ActRecTut	6	10	31.4~32.6	2	42	0.02~5.1
PAMAP2	11	9	253~408	10	18~25	2.0~40.3
USC-HAD	12	6	25.4~56.3	70	12	0.6~13.5
UCR-SEG	2~3	1	2~40	32	2~3	1~25

- 合成データ：TSAGen というツールを使用し、各々にランダムな時間幅を持つ 5 つの状態が遷移する合成時系列を生成した。

- MoCap：CMU モーションキャプチャデータセットであり、歩行、走行、跳躍、ダンスなどの状態ラベルが付与されている。

- ActRecTut：スポーツ活動から収集された加速度データが含まれ、実験では人々のウォーキングに関連するデータのサブセットを使用する。

- PAMAP2：8 人が実施した歩行や着席などの 24 の低レベルおよびサッカー動作などの高レベルの人間活動が含まれている。

- USC-HAD：14 人の人々が個別に記録した走行や跳躍などの 12 の人間活動が含まれている。

- UCR-SEG：医療、昆虫、ロボット、電力需要などから取得した単変量時系列のベンチマークデータセットである。

各データセットは平均値と分散で正規化 (z-normalization) して使用した。

5.1.2 比較手法

有効性を検証するために、以下の比較手法と比較を行った。

- AutoPlait：最小記述長原理を適用して MTS をセグメント化し、パラメータ調整やユーザーの介入なしで各セグメン

トを隠れマルコフモデルで再帰的にモデリングする。

- HVGH：多変量時系列 (MTS) ウィンドウのエンコードに変分オートエンコーダを使用し、クラスタリングには階層ディリクレプロセス (HDP) で状態数を自動推定する。

- TICC：状態数を指定が必要な手法であり、相関ネットワークをエンコードにし、トリプレット逆共分散に基づいてクラスタリングを行う。

- HDP-HSMM：隠れセミマルコフモデルを拡張したベイズ非パラメトリック手法であり、HDP で状態の数を推定する。

- ClaSP+TSKMeans：複数のバイナリ分類器を使用して MTS の変化点を特定し、KMeans でクラスタリングを行う。

- Ts2Vec：階層型の対照学習で任意の意味レベルでの時系列の表現を学習し、DPGMM で状態の数を自動推定する。

- Time2State：エンコードに時系列畳み込みネットワークを使用し、DPGMM で状態数を自動推定する。

5.1.3 評価指標

検出精度を評価するために、調整ランド指数 (ARI) と正規化相互情報量 (NMI) を使用する。ARI は予測クラスと真のクラス間の一致度を定量化し、クラスタリングの細かさ強調する一方、NMI は真のクラスタリングとモデルクラスタリング間の共有情報を測定する。

$$ARI = \frac{\text{Observed Index} - \text{Expected Index}}{\text{Max Index} - \text{Expected Index}} \quad (3)$$

Observed Index は推定したクラス分割と正解データとの一致数、Expected Index はランダムなクラス分割と正解データとの一致数、Max Index は理論的に達成可能な正解データとの一致数である。

$$NMI(U, V) = \frac{2 \cdot I(U; V)}{H(U) + H(V)} \quad (4)$$

U は正解ラベル、V は予想クラスであり、 $I(U; V)$ はどれだけ情報を共有しているかを示す相互情報量、 $H(U)$ と $H(V)$ は分布の不確定性を示すエントロピーである。 $I(U; V)$ を $H(U)$ と $H(V)$ で割る正規化を行い、比較の公平性を確保している。

5.1.4 実験環境の詳細

全ての実験は 512GB のメモリ、Xeon Gold 6258R 2.7GHz の 28 コア CPU および RTX A6000 48GB GPU を搭載した Linux マシン上で実施した。

5.1.5 ハイパーパラメータの最適化

公平な比較のため、AutoPlait を除くすべてのベースラインのパラメータを最適化する。AutoPlait はユーザーの介入やパラメータ調整を必要としない。データセットごとのパラメータ調整は可能であるが、すべての時系列ごとのパラメータ調整は困難であるため、元の論文で提供された戦略と推奨事項に基づいてハイパーパラメータを選択する。推奨事項がない場合は適切なハイパーパラメータ空間でグリッドサーチを行った。提案手法のパラメータ最適化ははるかに疎な空間で行われ、ウィンドウサイズとステップサイズをそれぞれ 128, 256, 512 および 25, 50, 75, 100 で共同最適化を行なった。クラスタリング手法については、DBSCAN, MeanShift, DPGMM の中で最も精度

表 3 Overall comparison.

Method	Synthetic		MoCap		ActRecTut		PAMAP2		UscHad	
	ARI	NMI	ARI	NMI	ARI	NMI	ARI	NMI	ARI	NMI
HVGH [11]	0.0809	0.1606	0.0900	0.1523	0.0881	0.2088	0.0032	0.0374	0.0788	0.1883
HDP_HSMM [12]	0.6619	0.7798	0.5509	0.7230	0.6644	0.6473	0.2882	0.5338	0.4678	0.6839
TICC [5]	0.6242	0.7481	0.7218	0.7524	0.7839	0.7466	0.3008	0.5955	0.3947	0.7028
AutoPlait [9]	0.0713	0.1307	0.8057	0.8289	0.0586	0.1148	N/A	N/A	0.2948	0.5413
ClasPTS_KMeans [13]	0.2950	0.4480	0.5450	0.6763	0.2825	0.2309	0.1700	0.5830	0.5075	0.6940
TS2Vec [14]	0.8176	0.8407	0.7529	0.7584	0.7670	0.7407	0.3135	0.5905	0.6522	0.8126
Time2State [15]	0.8843	0.8025	0.7896	0.7812	0.7909	0.7473	0.3345	0.6143	0.6833	0.8164
Proposed(Ours)	0.8802	0.8731	0.7603	0.7753	0.6144	0.6376	0.3090	0.5702	0.7804	0.8671

表 4 ablation study.

Method	ノイズ除去モジュール I/O	成分分割モジュール I/O	局所的な学習モジュール I/O	大域的な学習モジュール I/O	スライディングウィンドウ I/O
NMI	0.6745	0.6936	0.7108	0.7243	0.4787

UMAPによる特徴空間の可視化




図 6 Mocap データセットの 4 次元の時系列データに対して学習の段階である 5epoch, 25epoch, 50epoch において UMAP を用いた特徴空間の可視化を行なった. epoch が進むにつれて各クラスの混合度合いが小さくなっている.

が良い結果を記載している.

5.2 Q1：状態シーケンスの推定に対する提案手法の有効性

提案手法とベースライン手法の 6 つのデータセットにわたる全体比較を表 3 に示す. 提案手法は, ARI と NMI のスコアでどのデータセットに対しても一貫して高精度な結果を達成している. Autoplait は最短の平均 MTS 長を持つ MoCap データセットで優れており, 最高の ARI および NMI スコアを達成しているが, 処理時間は長く, 特に最長の平均 MTS 長を持つ PAMAP2 データセットを処理できない点が問題となっている. ClaSPTS_KMeans は, 単変量の UcrSeg データセットで最高の ARI および NMI スコアを達成している. 提案手法が合成データや UscHad で最高の ARI および NMI スコアを達成していることについて, ノイズ除去のモジュールを取り入れているため, ガウスノイズを加えて生成している合成データセットに対してノイズ除去が適切に機能したことや, UscHad は最多の状態数を持つため, 提案手法が特徴空間上に適切な分離を行ったからと考えられる.

5.3 Q2：提案手法のロス関数設計の有効性

案されたコンポーネントの有効性と効率性を評価するため,

アブレーションスタディを行う. ノイズ除去のモジュール, 成分分割のモジュール, 局所的な学習モジュール, 大域的な学習モジュールをそれぞれ使わずに精度検証をしたほか, スライディングウィンドウによる分割推論の状態パターン検出アルゴリズムの代わりに全体の時系列データに関して一括でエンコーディングを行い, 状態パターン検出を行った時の精度を表 4 に示す. Mocap データにおける実験結果のみを抜粋する. ノイズ除去の機構が最も有効に働いていることが示された.

5.4 Q3：提案手法の特徴空間におけるパターン情報保持の有効性

学習エポックを進めるごとに状態パターンが検出しやすいように特徴空間を可視化するために次元削減の手法の一つである UMAP を用いて高次元データである特徴空間を高次元データを低次元空間に投射した. 他の手法と比べてデータの局所的な構造と大域的な構造の両方を学習に優れたいる. 図 6 に示すように 5epoch, 25epoch, 50epoch ごとに特徴空間の可視化を行なったところ, 5epoch ではクラスタ構造が不明瞭であったが, 25,50epoch に学習が進むと他の色との混合度合いが小さくなり, それぞれの状態ごとにクラスタ構造を取り, 特徴空間において視覚的なパターン情報を持つようになっていくことが確認さ

れた。

5.5 Q4：状態数既知の場合や一括推論との有効性




図7 状態数既知や一括推論との精度比較

時系列データを一括でエンコードした場合と、分割時系列をエンコードしてパターン状態検出を行った精度の比較を行った結果と、横軸の0では適切なクラスタリングの状態数を設定し、1, 2と適切な状態数に過剰な数を設定した結果、状態数を設定しない提案手法の結果を同時に示している。これらの結果から分割推論にすることで2倍以上の精度が向上し、正しい状態数を設定した場合と提案手法が同様の精度が確認できた。

6 むすび

本論文では、大域的な情報と局所的な情報を活用する自己教師あり対照学習に基づく時系列セグメンテーション手法を提案した。提案手法は冒頭で確認した以下の優れている特性を全て達成している。

- 状態パターン数が未知の様々なデータに対して、適切なパターン数が学習してパターン検出を行い、適切なパターン数の検出が可能である。
- データの長さに依存することなく、様々なデータに対して実用的なパターン検出が可能である。
- 対照学習の重要な設計である組み合わせにおいて、バイアスを軽減する対照学習における正負の組み合わせを提案した。
- 時間領域と周波数領域に対するデータ拡張によってノイズ除去を行い、ノイズに強く、局所的な情報と大域的な情報の両方を捉える手法であり、従来の手法に対する優位性を実証した。

今後は検出した状態パターンに基づいて、行動予測や故障予測など、予測タスクに応用し、パターンに基づく使用者が理解しやすい予測アルゴリズムを研究する予定である。

謝辞 本研究の一部は JST CREST JPMJCR23M3 の助成を受けたものです。

文 献

[1] Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting. *Advances in neural information processing systems*, 34:22419–22430, 2021.

[2] Yong Liu, Haixu Wu, Jianmin Wang, and Mingsheng Long. Non-stationary transformers: Exploring the stationarity in time series forecasting. *Advances in Neural Information Processing Systems*, 35:9881–9893, 2022.

[3] Shengsheng Lin, Weiwei Lin, Xinyi Hu, Wentai Wu, Ruichao Mo, and Haocheng Zhong. Cyclenet: enhancing time series forecasting through modeling periodic patterns. *arXiv preprint arXiv:2409.18479*, 2024.

[4] Shohreh Deldari, Daniel V Smith, Amin Sadri, and Flora Salim. Espresso: Entropy and shape aware time-series segmentation for processing heterogeneous sensor data. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 4(3):1–24, 2020.

[5] David Hallac, Sagar Vare, Stephen Boyd, and Jure Leskovec. Toeplitz inverse covariance-based clustering of multivariate time series data. In *Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining*, pages 215–223, 2017.

[6] Minji Lee, Heon-Gyu Kwak, Hyeong-Jin Kim, Dong-Ok Won, and Seong-Whan Lee. Seriesleepnet: an eeg time series model with partial data augmentation for automatic sleep stage scoring. *Frontiers in Physiology*, 14:1188678, 2023.

[7] Stéfano Frizzo Stefenon, Matheus Henrique Dal Molin Ribeiro, Ademir Nied, Kin-Choong Yow, Viviana Cocco Mariani, Leandro dos Santos Coelho, and Laio Oriel Seman. Time series forecasting using ensemble learning methods for emergency prevention in hydroelectric power plants with dam. *Electric Power Systems Research*, 202:107584, 2022.

[8] Kouki Kawabata, Yasuko Matsubara, and Yasushi Sakurai. Streamscope: Automatic pattern discovery over data streams. *Proceedings of the First International Workshop on Exploiting Artificial Intelligence Techniques for Data Management*, 2018.

[9] Yasuko Matsubara, Yasushi Sakurai, and Christos Faloutsos. Autoplait: automatic mining of co-evolving time sequences. In Curtis E. Dyreson, Feifei Li, and M. Tamer Özsu, editors, *International Conference on Management of Data, SIGMOD 2014, Snowbird, UT, USA, June 22–27, 2014*, pages 193–204. ACM, 2014.

[10] Muxi Chen, Zhijian Xu, Ailing Zeng, and Qiang Xu. Fraug: Frequency domain augmentation for time series forecasting. *arXiv preprint arXiv:2302.09292*, 2023.

[11] Masatoshi Nagano, Tomoaki Nakamura, Takayuki Nagai, Daichi Mochihashi, Ichiro Kobayashi, and Wataru Takano. Hvgh: unsupervised segmentation for high-dimensional time series using deep neural compression and statistical generative model. *Frontiers in Robotics and AI*, 6:115, 2019.

[12] Yee Teh, Michael Jordan, Matthew Beal, and David Blei. Sharing clusters among related groups: Hierarchical dirichlet processes. *Advances in neural information processing systems*, 17, 2004.

[13] Arik Ermshaus, Patrick Schäfer, and Ulf Leser. Clasp: parameter-free time series segmentation. *Data Mining and Knowledge Discovery*, 37(3):1262–1300, 2023.

[14] Zhihan Yue, Yujing Wang, Juanyong Duan, Tianmeng Yang, Congrui Huang, Yunhai Tong, and Bixiong Xu. Ts2vec: Towards universal representation of time series. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 8980–8987, 2022.

[15] Chengyu Wang, Kui Wu, Tongqing Zhou, and Zhiping Cai. Time2state: An unsupervised framework for inferring the latent states in time series data. *Proceedings of the ACM on Management of Data*, 1(1):1–18, 2023.