

修士論文

自己教師あり対照学習を活用した 多変量時系列の部分セグメンテーション

加藤翼

令和7年2月5日

大阪大学大学院情報科学研究科
情報システム工学専攻

修士論文

自己教師あり対照学習を活用した 多変量時系列の部分セグメンテーション

加藤翼

令和7年2月5日

大阪大学大学院情報科学研究科
情報システム工学専攻

修士論文

自己教師あり対照学習を活用した 多変量時系列の部分セグメンテーション

— 論文概要 —

加藤翼

令和7年2月5日

大阪大学大学院情報科学研究科
情報システム工学専攻

物理センサーが生成した時系列データは、多様な状態パターンに変化し、各時刻での状態の識別可能な特徴を持つため、対象物の現在の状態や過去の状態遷移の認識が対象物の行動理解や未来の状態予測に役立つ。本論文では自己教師あり対照学習を活用し、多変量時系列から複数の潜在状態と状態数を自動で特定し、部分時系列の状態遷移の解析手法を提案する。提案手法では、ラベル付きデータを必要とせず、事前に状態の数を知る必要がないこと、スライディングウィンドウを用いた部分時系列の特徴抽出を行い、潜在空間上でクラスタリングを行うことで、時間的に離れた同一パターンを同じ状態として認識し、不適切なバイアスの軽減によって異なるパターンの誤検出を抑制した。実データを活用した実験により、提案手法が時系列データの長さに依存せず、既存手法と比較して高精度であることを明らかにした。

MASTER'S THESIS

**Leveraging Self-Supervised Contrastive
Learning for Partial Segmentation of
Multivariate Time Series**

Synopsis

TSUBASA KATO

Feb. 5, 2025

Department of Information Systems Engineering
Graduate School of Information Science and Technology,
Osaka University

In massive, noisy, and rapidly changing multivariate time-series data, multivariate modeling or multi-data analysis is necessary for pattern detection. How can we effectively extract features that alleviate the constraints of data-intensive processes and are suitable for practical applications in pattern detection?

Time-series data generated by physical sensors undergo diverse state pattern variations and possess identifiable features at each timestamp. Recognizing the current state of a target object and its past state transitions aids in understanding its behavior and predicting future states. In this paper, we propose a method for analyzing state transitions in partial time-series data by leveraging self-supervised contrastive learning. The proposed method automatically identifies multiple latent states and the number of states from multivariate time-series data without requiring labeled data or prior knowledge of the number of states. By extracting features from partial time-series segments using a sliding window and performing clustering in the latent space, the method recognizes temporally distant but identical patterns as the same state while mitigating inappropriate biases to suppress the misdetection of different patterns. Experiments using real-world data demonstrate that the proposed method is independent of the length of time-series data and achieves higher accuracy compared to existing methods.

自己教師あり対照学習を活用した
多変量時系列の部分セグメンテーション

加藤翼

目次

第1章	はじめに	1
1.0.1	本論文の貢献	4
第2章	関連研究	5
2.0.1	統計的解析手法	5
2.0.2	深層学習を用いた手法	7
2.0.3	数理モデルに基づく時系列セグメンテーション	10
2.0.4	深層学習モデルに基づく時系列セグメンテーション	11
2.0.5	時系列の表現学習	13
2.0.6	クラスタリング	17
2.0.7	ノンパラメトリックベイズモデル	18
第3章	問題定義	20
3.0.1	自己教師あり対照学習	20
3.0.2	問題定義	21
第4章	提案手法	23
4.0.1	ノイズ除去	23
4.0.2	成分分解	24
4.0.3	デュアル学習	25
4.0.4	状態パターン検出アルゴリズム	28
第5章	評価実験	30
5.0.1	実験設定	30
5.0.2	Q1：状態シーケンスの推定に対する提案手法の有効性	33
5.0.3	Q2：提案手法のロス関数設計の有効性	34
5.0.4	Q3：提案手法の特徴空間におけるパターン情報保持の有効性	34
5.0.5	追加実験	34
第6章	むすび	35
	謝辞	36
	参考文献	37

目 次

1.1	Mocap データセットの状態パターン	2
1.2	提案手法の概要図	3
2.1	状態空間モデルのグラフィカルモデル	6
2.2	隠れマルコフモデルの状態遷移図	6
2.3	RNN の構造	7
2.4	RNN, LSTM, GRU の構造の比較	8
2.5	Transformer の構造 ^[1]	9
2.6	AutoPlait による時系列セグメンテーション ^[2]	10
2.7	RegimeCast における非線形動的システムを用いたレジームの表現 ^[3]	11
2.8	TICC による時系列セグメンテーション ^[2]	12
2.9	HVGH による時系列セグメンテーション ^[2]	13
2.10	TS-TCC の概要 ^[2]	14
2.11	TNC の概要 ^[2]	15
2.12	InfoTS の概要 ^[2]	15
2.13	TimesURL の概要 ^[2]	16
2.14	CoST の概要 ^[2]	16
2.15	DTCCR の概要 ^[2]	17
2.16	Stick Breaking Process (SBP) の概要 ^[2]	19
2.17	Hierarchical Dirichlet Process (HDP) の概要 ^[2]	19
4.1	データ拡張の概要図	23
4.2	局所的パターン抽出の概要図：時系列をスライディングウィンドウで分割し、それぞれで統計的特徴量を計算し、近いものを正のペアに、遠いものを負のペアにしてそれぞれ $\mathcal{L}_{\text{positive}}$, $\mathcal{L}_{\text{negative}}$ を計算し、局所的なパターンを学習する.	27
4.3	検出アルゴリズムの概要図：時系列をスライディングウィンドウで分割してエンコーダによって特徴表現に変換した後、クラスタリングを行い、各ウィンドウに検出した状態インデックス割り当てを行う。その後各観測点に複数の状態インデックス割り当てが行われているため、最多のインデックスを最終的な状態パターンとする.	29
5.1	Mocap データセットの 4 次元の時系列データに対して学習の段階である 5epoch, 25epoch, 50epoch において UMAP を用いた特徴空間の可視化を行なった。epoch が進むにつれて各クラスの混合度合いが小さくなっている。	32

表 目 次

3.1	主な記号と定義	22
5.1	データセット詳細	30
5.2	Overall comparison.	31
5.3	ablation study.	31

第1章 はじめに

時系列データは金融動向や需要予測, 気候モデリング, 自動運転や心拍数, 運動動作, 睡眠などの生体情報に基づく健康管理のアプリケーションなど多くの場面で活用されている。[4, 5, 6] これらの時系列データは監視対象の状態変化を捉える豊富な情報を含んでおり, パターン認識やイベント検出, 異常検知, 故障パターンの推定に役立つ。

自動運転データでは, 曲がる, 直進, 停止, 加速などの状態パターン情報を含み, 睡眠データでは睡眠の深さや中途覚醒などの睡眠パターン, 工場機械の監視センサでは機械が故障するまでの遷移パターンが存在する。[7, 8, 9, 10, 11, 12] これらを正確に認識することで人手を使わないタグ付けやパターン検出, 将来パターンの予測につながる。本研究の目標は与えられた時系列から潜在状態のパターン遷移ができるような特徴表現を獲得することである。

テキストデータや画像・音声・動画などのマルチメディアデータと違い, 時系列データのパターン認識では個々のデータ点に注目するよりも, より広いコンテキストでデータを理解するアプローチがクラスタリングや分類タスクに有用である。教師あり状態検出は, 既知の多次元時系列セグメントとそのラベルの組みを必要とするが, ラベルが既知の場合は限定的なケースである場合が多いため, 教師なし状態検出への関心が高まっている。教師なし状態検出は既知のセグメントやそのラベルに依存せずに直接多次元時系列内の異なる状態を識別することができる。時系列解析研究の中にはイベント点検出に重点を置く研究があるが, イベント点検出では時系列の状態が変化した時間点を検出すればよいのに対し, 状態検出では変化した時間点に加えて, その部分時系列がどのような状態であるかの推定や, 再度同じ状態が現れた際に過去の状態と同様であるとラベル付けができるように時系列の状態特性や状態数についてアルゴリズムとして記憶する機構が必要である。

教師なし状態検出プロセスが完了した後に, 検出された各状態インデックスに意味のあるラベルを割り当てるために最小限の人間の介入や解釈が必要であり, 事前にパターンの種類数が未知の場合が多く, 十分なラベル付きデータがないことから教師なし学習の研究が進んでいる。パターン検出では, 各観測点に対して, 十分に類似した既存のパターン, もしくは類似したパターンがない場合は新たなパターンとして割り当てるクラスタリングの使用が一般的である。ここでは同じ状態を持つ連続する観測点はシーケンスとして統合する。

図1に示されるように人のモーションダンスの例では, 事前にダンス状態の数や種類を知る必要はなく, 結果に基づいてダンス状態を識別してラベル付けできます。この柔軟性は, サイバー攻撃やウェブアプリケーションの動作などのオープンエンドの検出タスクに




図 1.1: Mocap データセットの状態パターン

Mocap データセットから左/右腕, 左/右足に対応する 4 次元の時系列データを示している. 各状態パターンが人のモーションに対応しており, 任意の時間幅で次の状態パターンに遷移している.

も活用が可能である.

一般的な状態パターンの検出アプローチでは与えられた時系列データをウィンドウサイズごとにエンコードして潜在埋め込み表現を獲得し, その後クラスタリングによって状態検出を行っている. このアプローチではエンコードの段階とクラスタリングの段階を個別に考えられる. しかし以下の3つの主要な課題が残っている.

- ラベル付きデータがない場合, 事前に状態の数を知ることは通常難しい. そのため状態の数がわからない場合でも効果的であるべきであり, データから自己学習によって適切な状態の数を学習してラベル付けすることが重要な課題である.
- 最先端のエンコーダーの学習手法は, 教師なしコントラスト学習に基づいており, 類似サンプル間の類似性の最大化, 異なるサンプル間の類似性の最小化が目的である. このアプローチでは, 遠隔ウィンドウが異なる状態を持つという理想的な仮定のために, 遠隔ウィンドウが同一パターンである場合の誤検出や隣接ウィンドウで異なる状態の場合に同一状態としての検出に陥りやすく, クラスタリングに適した埋め込み空間の形成の堅牢性を確保することが重要な課題である.
- 特徴空間にエンコードする際に, 小さな差異によって異なる特徴空間に投射するため, 時間軸に沿ったパターンの変化の意味的な情報が消失してしまう. ノイズを除去する

必要があることや、局所的な特徴と長期的な特徴をもとに特徴空間上でパターンの視覚的な変化情報の取得が、将来予測や未知の状態特定アプローチにとって重要な情報であり、有益な特徴空間の構築が課題となっている。

本研究で提案する自己教師あり対照学習を活用した多変量時系列の部分セグメンテーションのための深層学習フレームワークの概要を図2で示す。




図 1.2: 提案手法の概要図

入力時系列はデータ拡張としてフーリエ変換で低周波成分の抽出によってノイズ成分の除去を行い、季節成分とトレンド成分に分割する。その後エンコーダを通して長期的なパターンと局所的なパターンを捉える特徴表現として特徴空間に投射する。その後表現空間上で統計的特徴量が近いパターンが近づき、遠いパターンが遠ざかるように対照学習を行う。

本アルゴリズムは、データ拡張、特徴空間へのエンコーディング、対照学習による表現学習の3つの段階に分かれている。入力データに対してデータ拡張としてノイズ除去や季節成分とトレンド成分の分解を行うことで入力データの解釈性の向上を行い、エンコーディングでは局所的な情報と長期的な情報を捉える2つの特徴学習モジュールを持つ。その後、対照学習によって状態パターンの特徴を捉え、類似度を示すパターンごとの空間的な距離の近さによってパターンのクラスタ判別を決定し、様々な時系列データの状態パターン検出への適応が可能である。

上記で述べた3つの主要な課題について第1の要件を満たすために、学習された表現から状態の数を推定するためにノンパラメトリックベイズ法のDPGMMや密度ベースのHDB-SCANやMeanShiftを採用する。

第2の要件を満たすために、時系列データの局所的な滑らかさとマルコフ特性のため、大部分の時系列セグメントは簡単なネガティブサンプルと見なされる。これらのセグメントはアンカーとの意味的な違いが大きく、識別に役立つ情報をほとんど提供しないため学習に貢献するのはわずかな勾配だけである。完全に同一ではないアンカーと類似した少数のハードネガティブサンプルを含めることで学習が改善され効率が高まることが示されており、アンカーに似た統計的特徴量やスペクトルエネルギー、主要周波数成分の類似度に応じて、教師なしコントラスト学習の正負のペアを決定する。

第3の要件を満たすために、ノイズ除去のために時間的変動と依存関係を維持するために時間領域でのクロッピングと周波数領域でのミキシングを組み合わせたデータ拡張を行い、局所的な特徴と長期的な特徴を捉えるために、任意の部分系列の文脈表現を学習する階層的な構造を採用し、ロス関数において近い観測点は特徴空間で近づくように設計し、特徴空間上で視覚的な情報が保存されるように学習する。

1.0.1 本論文の貢献

本論文の貢献をまとめると次の特徴を持つ。

- 状態パターン数が未知の様々なデータに対して、適切なパターン数が学習してパターン検出を行い、適切なパターン数の検出ができることを確認した。
- 教師なしコントラスト学習における似た別状態を正しく識別することを目的とした対照学習手法を提案する。これは考案した類似性に基づく潜在的な正負のペアの決定によって達成され、精度の向上を確認した。
- 時間領域と周波数領域に対するデータ拡張によってノイズ除去を行い、局所的な特徴と長期的な特徴を捉える階層構造や特徴空間上で時間軸に沿って連続的なパターンの変化が捉えられるロス関数の設計を行った。
- 6つの実世界のデータセットと6つのベースラインを用いた広範な実験により、提案手法の効果、スケーラビリティ、汎用性の観点から、従来の手法に対する優位性を実証する。

本論文の構成は以下の通りである：

第2章では関連研究について述べる。第3章では自己教師あり学習と研究の問題設定。第4章では提案手法の詳細、つまり学習モジュールと状態パターンの検出モジュールについて説明する。第5章では評価実験、第6章では応用例について述べる。最後に第7章で本論文をまとめる。

第2章 関連研究

2.0.1 統計的解析手法

時系列データの古典的な解析手法で最も基本的なものとして自己回帰 (AR: Autoregressive Model) モデルが挙げられる。これは1次元の時系列データ $\mathbf{x} = \{x_1, x_2, \dots, x_{t-1}\}$ が与えられた時、 t 時点の値を過去の自身の値を用いて回帰するモデルである。この自己回帰モデルをベースとして、ARMA (Auto Regressive Moving Average), ARIMA (Auto Regressive Integrated Moving Average), SARIMA (Seasonal Auto Regressive Integrated Moving Average), ARIMAX (Auto Regressive Integrated Moving Average with Exogenous variables) など様々な派生手法や拡張モデルが開発され、中でも ARIMA はシンプルなモデルであるにもかかわらず高精度に時系列データをモデリング可能なため様々な用途に用いられている。例えば1階差分系列に対する ARIMA(p, 1, q) モデルでは次式のように x_t を回帰する。

$$y_t = x_t - x_{t-1} \quad (2.1)$$

$$\begin{aligned} y_t &= c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q} + \epsilon_t \\ &= c + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \epsilon_t \end{aligned} \quad (2.2)$$

ここで、 c は定数項、 $\phi = \{\phi_1, \dots, \phi_p\}$ および $\theta = \{\theta_1, \dots, \theta_q\}$ はパラメータ、 $\epsilon = \{\epsilon_1, \dots, \epsilon_t\}$ は誤差項、 $\mathbf{y} = \{y_2, \dots, y_t\}$ は $\mathbf{x}$ の1階差分系列である。

他にも、時系列データの統計的解析手法としては状態空間モデルに基づく手法も広く用いられている。状態空間モデルは観測可能な変数の他に、観測できない潜在変数という変数を想定するモデルである。ここで、各時点の観測変数 $\mathbf{x}_t$ に対応する潜在変数 $\mathbf{z}_t$ が存在し、 $\mathbf{x}_t$ は $\mathbf{z}_t$ によって条件づけられる。状態空間モデルではこれら潜在変数はマルコフ連鎖を構成すると仮定される。このような状態空間モデルは図2.1に示すようなグラフィカルモデルを構成する。




図 2.1: 状態空間モデルのグラフィカルモデル

状態空間モデルは，その潜在変数が離散値か連続値かで大きく2つに分類される．離散値の潜在変数を扱う状態空間モデルとして広く用いられているものとしてHMM，連続値の潜在変数を扱うものとしてカルマンフィルタが挙げられる．HMMは音声認識や言語処理などの様々な分野で時系列パターンの認識のために用いられている^[13, 14]．HMMは各潜在変数をそれぞれ1つの状態に対応させたオートマトンとして捉えることもできる．潜在変数が3つの値を取る場合(すなわち状態数が3の場合)の状態遷移図を図2.2に示す．




図 2.2: 隠れマルコフモデルの状態遷移図

図中の $z_t = k, \{k = 1, 2, 3\}$ で示されるノードはHMMの潜在変数であり状態遷移図における各状態である．また A_{ij} は状態 i から状態 j への状態遷移確率を示す． b_i は状態 i において x_t を出力する出力確率 $b_i = p(x_t|z_t)$ である．ここで，観測変数 x_t が潜在変数 z_t によって条件付けられて生成される様子を，状態の遷移とは区別して灰色の破線で示している．

2.0.2 深層学習を用いた手法

近年深層学習に基づく時系列解析手法が広く研究されている．深層学習に基づくアプローチでは，前項で述べた統計的解析手法と比較してより表現力の高い柔軟なモデルを構築することができる．したがって，非定常かつ非線形な複雑な時系列データを扱う際に有用である．しかし一方で大量の学習データが必要であったり，学習に多くの時間がかかってしまったりなどの欠点も含んでいる．時系列データを扱う深層学習モデルの最も基本的なものとして再帰型ニューラルネットワーク (RNN: Recurrent Neural Network)^[15] が挙げられる．RNNの構造を図2.3に示す．




図 2.3: RNNの構造

図2.3(a)にあるように，RNNは入力層，出力層，そしてRNNセルと呼ばれる一層の中間層で構成され，入力 x_t がRNNセルを通して出力 y_t として得られる．ここで，RNNが一般の深層学習モデルと異なるのは，前の時点の中間層の出力 h_{t-1} が現在時点の中間層の計算に用いられるという再帰的な構造を有している点である．

このようなRNNの再帰の構造を各時点ごとに展開したものが図2.3(b)である．このように以前の時刻の中間層の状態が次の時刻へと引き継がれていくことで，時点間の依存関係をモデリングすることができる．

RNNをベースとして，RNNの勾配消失や長期記憶が難しいといった欠点を改善した手法も開発されており，広く用いられているものにLSTM^[16]とGRU^[17]が挙げられる．これらは

図2.3(a)に示すような再帰的な構造はRNNと共通しており，RNNセルに相当する中間層の構成が異なっている．

LSTM，GRUの中間層はRNNセルと同様LSTMセル，GRUセルと呼ばれ，それらは図2.4に示すような構造を持つ．




図 2.4: RNN, LSTM, GRU の構造の比較

LSTMはSigmoid関数を用いたゲートと呼ばれる構造を有しており，このゲートにより不要な情報を棄却し重要な情報のみ記憶するという機能を実現した．したがってLSTMの中間層では h_t ， c_t という2つの変数でそれぞれ短期記憶，長期記憶の状態を表現する．これらゲートと2つの状態変数の働きによりRNNの課題である長期記憶と勾配消失，勾配爆発問題を克服した．しかし，LSTMには複数のゲートの追加によりパラメータ数が増加したことが原因で学習速度が遅くなるという問題があった．そこで，LSTMと同等の性能を実現し，かつパラメータ数がLSTMと比較して少なく学習が高速に行えるモデルとしてGRUが提案された．GRUもLSTMと同様ゲートを用いて情報の取捨選択を行うが，LSTMが3つのゲートを用いるのに対しGRUはゲート数が2である．また，LSTMは過去情報を保存するのに c_t ， h_t の2つの変数を用いたが，GRUでは1つの変数のみで短期，長期両方の記憶を実現する．このようにGRUはLSTMと比較してモデルがコンパクトであり，したがって高

速な学習が実現できる。

また、同じく深層学習に基づく時系列解析手法として広く用いられる手法にTransformer^[1]が挙げられる。TransformerはEncoder-Decoderモデルの一種であり、RNN等の再帰的なモジュールを用いず主として注意機構(Attention)^[18]によって構成されている点が特徴的である。Transformerの構造を図2.5に示す。また、近年Transformerをベースとした時系列解析手法がさまざま提案されており、例えばAutoformer^[19], Informer^[20], FEDformer^[21], Pyraformer^[22]などが挙げられる。




図 2.5: Transformer の構造^[1]

2.0.3 数理モデルに基づく時系列セグメンテーション

時系列データを固有のパターンごとに分類するセグメンテーションも時系列データを扱う際には有効なアプローチである．これはある系列全体を一つのクラスに分類するクラスタリングとは異なり，時系列セグメンテーションでは一つの系列の中でもどの部分系列がどのクラスに属するかをより詳細な粒度で分類する．時系列データをセグメンテーションすることで，そのセグメンテーション結果を異常検知や将来予測に応用することができる．時系列セグメンテーションの手法としてRegimeCast^[3]，OrbitMap^[23]，AutoPlait^[2]，CubeMarker^[24]などが挙げられる．図2.17にAutoPlaitによる時系列セグメンテーションの具体例を示す．




図 2.6: AutoPlait による時系列セグメンテーション^[2]

図の上段はセグメンテーションの対象となる元の時系列を示す．ここでは人体に取り付けた4次元のモーションセンサーのデータを用いており，”beaks”，”wings”，”tail feathers”，”claps”という4種のモーションが含まれている．下段がAutoPlaitによるセグメンテーション結果であるが，正しく4種の動作を分類できている．

これらの手法では固有の時系列パターン，即ちクラスターをレジーム (Regimes) と呼称しており，例えばRegimeCastではレジームを非線形動的システムでモデリングしている．その非線形動的システムによるレジームのモデリングの例を図2.7に示す．

ここでも図2.17と同様に4次元のモーションキャプチャのデータを用いており，各グラフにおいて灰色の破線は実際のデータ，色付きの実線は非線形動的システムでフィッティングした結果を示している．左，中央，右の図はそれぞれ拭き掃除，窓拭き，歩行のモーション




図 2.7: RegimeCast における非線形動的システムを用いたレジームの表現^[3]

のレジームを示す。RegimeCastではこのように各時系列パターンごとにモデルを構築し、それを応用して高精度な長期予測を実現している。

2.0.4 深層学習モデルに基づく時系列セグメンテーション

状態パターン分割の既存手法には教師あり学習と教師なし学習の手法に分けられるが、本研究ではラベルデータがない状況を想定しているため、教師なし学習の手法にのみ焦点を当てる。さらに状態数の入力が必要な手法と自動で推定する手法がある。

最初のカテゴリの代表的な研究として、TICCはトープリッツ逆共分散に基づく方法である。

各クラスターはそのクラスターの典型的な部分系列における異なる観測の依存関係の特徴付ける相関ネットワークによって定義され、クラスターに属するセグメント内の任意のウィンドウにおける時間不変の部分相関構造を決定する。この手法では事前知識に大きく依存し人為的介入が必要である。クラス数が事前に指定されていない場合にこれらの方法は機能せず、クラス数の推定を行うように修正することは難しい。実データではクラス数が実際に利用可能でないことが多いため、実用性に欠けている。





図 2.8: TICC による時系列セグメンテーション [2]

一方, 2 番目のカテゴリはより実用的だが, ほとんど研究されていない. AutoPlait は最小記述長 (MDL) を使用してクラス数を推定し, HVGH[25] は変分オートエンコーダ (VAE) と階層的ディリクレ過程 (HDP) を組み合わせてクラスタ数を推定する. クラス数を指定する必要はないが, AutoPlait は MDL ベースの損失を貪欲に最適化するために複数回の最適化が必要であり, 不安定な実行時間と低いスケーラビリティを引き起こす. HVGH は VAE と HDP の相互学習を複数回行う必要があり, スケーラビリティが大幅に低下する.

図 2.9: HVGHによる時系列セグメンテーション^[2]

2.0.5 時系列の表現学習

時系列データの表現学習は長年にわたり研究されているが、教師なしの表現学習というより困難な側面に焦点を当てた研究はまだ少ない状況である。表現学習はエンコーダを使用して生データから表現を学習し、それを低次元の埋め込み空間にマッピングする。数多くの時系列表現学習方法が存在するが、セグメント化を下流タスクと考慮する方法は非常に少なく、下流タスクは分類や予測が多いため、データの全体的な類似性に重点を置いている。また、時系列全体の表現を学習する傾向があり、セグメント化には適していない手法が多い。さらに細分化するとコントラスト学習のロス関数の設計とエンコーダ・デコーダの設計に焦点を当てた研究が存在する。

ロス関数の設計手法においては、TS-TCCは時系列データから頑健な表現を学習するための難易度の高い前提タスクを設計することに焦点を当てており、異なるタイムスタンプやデータ拡張によって生じる変動に対抗する厳しいクロスビュー予測タスクを設計する。TNCは隣接サンプルと非隣接サンプルを区別し、サンプルの重み調整を行う新しい近傍ベースで非定常な多変量時系列におけるポジティブおよびネガティブペアの選択し、Triplet-Lossはアンカーサンプルと負のサンプル間の距離を最大化し、アンカーサンプルと正のサンプル間の距離を最小化するロス関数を設計している。






図 2.10: TS-TCC の概要^[2]

InfoTSは適切な拡張の選択の重要性を強調し、メタ学習を用いて拡張を自動的に選択する手法を設計し、既成の知識の導入を防ぐ。TS2Vecは任意の部分系列に対してさまざまな意味レベルで文脈的な表現を学習する統一フレームワークであり、TimesURLはTS2Vecのポジティブペアおよびネガティブペアの構築の改良を行った。CoSTはモデルアーキテクチャにおける誘導バイアスを利用して前提タスクの設計に貢献しており、季節性とトレンドの分離された表現を学習し、識別的な季節性表現を促進するために新しい周波数領域のコントラスト損失を設計している。

図 2.11: TNC の概要^[2]図 2.12: InfoTS の概要^[2]

エンコーダ・デコーダの設計手法においては, SPIRALは時系列データと静的クラスタリングアルゴリズムの間のギャップを埋め, 生データに内在するペア間の類似性を効果的に保持する特徴表現を学習する. TimeNetはリカレントニューラルネットワークでエンコーダ・デコーダのペアを学習し再構成誤差を最小化する. DTCRはseq2seqモデルに時間再構成とK-meansの目標を組み合わせ, クラスタ特有の時間表現を学習し, ROCKETは計算コストが少なく高速な分類方法で, ランダム畳み込みカーネルを使用して時系列を変換し, 線形分類器を訓練する.




図 2.13: TimesURL の概要 [2]





図 2.14: CoST の概要 [2]

これまでの多くの研究は、教師なしの時系列表現学習において再構成誤差を最小化するエンコーダ・デコーダアーキテクチャの開発に集中しており、時系列データに存在する固有の相関関係を利用や時間的な関係の変化に注目しているが、不適切な事前の仮定やデータ拡張手法、多すぎる簡単なネガティブサンプル、下流タスクに十分な情報がない、セグメントの情報を活用できていないことが挙げられる。

図 2.15: DTCR の概要^[2]

2.0.6 クラスタリング

パターン状態の検出の際にクラスタリングを行う。K-means やスペクトルクラスタリングなどの既存方法はクラスタ数の入力が必要であり、ここではクラスタ数が未知の場合に対応可能なクラスタリング手法について焦点を当てる。

X-means は K-means の拡張版であり、クラスタ数を自動的に推定する手法である。情報基準（BIC）を用いてクラスタ分割の適切性を評価し、最適なクラスタ数を決定するが、K-means と同様に球状クラスタを仮定しており、非線形なクラスタ形状への対応力は限定的である。DBSCAN は密度ベースのクラスタリング手法で、データポイントの密集度を基準にクラスタを構築する。クラスタ数の指定は必要ないが、パラメータとして近接距離や最小ポイント数を設定する必要がある。OPTICS は DBSCAN の拡張版であり、近接距離や密度に基づく順序を生成し、クラスタ構造を視覚的に分析することができる。MeanShift はデータの密度最大点（モード）を探索する手法であり、局所的なカーネル密度推定（Kernel Density Estimation, KDE）に基づきデータポイントを高密度領域へシフトさせる反復プロセスを通じてクラスタを形成する。バンド幅（カーネルのサイズ）を適切に設定する必要がある。大規模データでは計算コストが高くなるという課題がある。Density-peak クラスタリングは局所密度と他の高密度ポイントまでの最小距離を基準にクラスタ中心を識別する方法である。クラスタ数を事前に指定する必要がなく、密度の高い領域を自然に分離する能力を持つ。ディリクレ過程ガウシアン混合モデルはクラスタ数に対する事前分布としてディリクレ過程を採用したノンパラメトリックベイズ法である。観測データはガウシアン混合モデルから生成され、クラスタ数はデータに応じて自動的に適応される。近似推論には変分推論が用いられ、状態の数やクラスタリングの構造を柔軟に推定できる。

2.0.7 ノンパラメトリックベイズモデル

混合モデルにより状態数を混合成分として捉えて、離散的な多項分布を生成可能とするディリクレ過程 (Dirichlet Process (DP)) [91] を用いて混合モデルの事前分布の設計をする手法が提案されてきた [92, 93, 94]. しかし、単純なディリクレ過程では、一つのデータ群に含まれるクラス数のモデル化は可能であるが、ディリクレ過程がお互いに独立しているため異なるデータ群と共通するクラスの間係を考えることができない. そのため異なるデータ群においてもクラスを共有する階層的なディリクレ過程である階層ディリクレ過程が提案されている.

パラメトリックな混合モデルではクラス数は有限であり、有限次元のディリクレ分布から多項分布のパラメータが生成され、この多項分布から隠れ状態が決定される. ベイズ情報量基準 (BIC) [95] や赤池情報量基準 (AIC) [96] を用いてクラス数を推定することが可能である. しかし、これらの手法ではクラス数とモデルのパラメータは別々に推定されるためクラス数の選択にパラメータ推論が大きく影響を受けることや、クラス数ごとに AIC や BIC を計算する必要があり計算コストが高い.

一方、ノンパラメトリックベイズモデルでは、データに応じてモデル自体の複雑さも自動的に学習することができる. ノンパラメトリックとはデータにフィットする柔軟な無限次元の離散分布を考えることを意味し、モデル自体の複雑さを学習することで、隠れマルコフモデルの状態数をデータから低コストに推定することが可能となる. 例えば、連続的な時系列データに対して、分節のクラス数を予め少なく設計する場合に、多少類似する異なる分節は同一クラスに分類されてしまう. 一方クラス数が多すぎれば極端な場合、各分節にそれぞれ異なるクラスが割り当てられることになりクラスタリングが意味をなさない. ノンパラメトリックベイズモデルでは、無限個のクラスを仮定しているために無限次元の多項分布を生成する必要があり、その構成法の1つに Stick Breaking Process (SBP) がある [97].

SBP では、長さ 1 の棒をベータ分布からサンプリングされる値 v_k により、折り続けることで無限次元の多項分布 β を構成するディリクレ過程であり、次式で表される.

$$v_c \sim \text{Beta}(1, \gamma) \quad (c = 1, \dots, \infty) \quad (2.1)$$

$$\beta_c = v_c \prod_{i=1}^{c-1} (1 - v_i) \quad (c = 1, \dots, \infty) \quad (2.2)$$

これにより、無限次元の多項分布のパラメータ β を構築することができる. このプロセスは一般的に $\beta \sim \text{GEM}(\gamma)$ と表記される [7].

ディリクレ過程を用いることで、無限の状態数をもったHMMの遷移確率を構成することができる. しかし、単にSBPによって各状態の遷移確率を構成するだけでは、状態毎に可




図 2.16: Stick BreakingProcess (SBP) の概要^[2]

能な遷移先が異なることになる。HMMのようなモデルの場合、全ての状態において可能な遷移先が共有されており、その遷移確率が状態毎に異なる分布を構成しなければならない。そのため、図2.4で示すように、SBPによって生成した分布 β を基底測度として共有し、状態 c 毎に異なる遷移確率 π_c をディリクレ過程によって生成する。

$$\pi_c \sim \text{DP}(\eta, \beta) \quad (2.3)$$




図 2.17: Hierarchical Dirichlet Process (HDP) の概要^[2]

このような、二段階のディリクレ過程によって無限次元の確率分布を構成する手法は、Hierarchical Dirichlet Process (HDP) と呼ばれている。これによって状態数が未知の場合にも無限次元を仮定することで、適切な状態数を推定できる。

第3章 問題定義

3.0.1 自己教師あり対照学習

効果的なデータ表現を教師ラベルなしで学習し、それをさまざまな下流タスクに容易に拡張できるようにすることは、長年の課題であった。主流のアプローチは、生成モデルまたは識別モデルの2つの教師なし学習のいずれかに分類できる。生成モデルは、データの基本的な分布を明示的に学習する。

しかし、これらのモデルは計算コストが高く、大規模なデータセットが必要であり、データ量が重要である。一方、識別モデル、特に自己教師あり学習は、データ表現において近年注目を集め、さまざまな研究分野で優れた性能が示されている^[?, ?]。自己教師あり学習では教師あり学習で使用される目的関数に似た目的関数を使用する。この目的関数の目標は、データセット内の各サンプルを異なるクラスとして扱うことである。目標は、類似したサンプルを近づけ、異なるものを遠ざける表現を学習することであり、**対照学習**として知られている。これらは、(i) プレテキストと(ii) 対照損失関数 の2つの要素を組み合わせている。

- プレテキストは、データのドメイン知識を利用して良い表現を学習するために、ラベル監視を置き換えるラベルのようなタスクを設定することを指す。対象は、テキストや画像の局所的なパッチとグローバルな意味^[?]、視覚特徴のさまざまなビュー^[?]、または時系列データにおける過去のシーケンスと将来の値^[?]などがある。
- 対照損失関数は、プレテキストを実行することでデータ間の相互情報を最大化することによりデータの類似性を学習する^[?]。相互情報は次のように定義できる：

$$I(x, z) := \mathcal{H}(z) - \mathcal{H}(z|x), \quad (3.1)$$

ここで、 $\mathcal{H}(z)$, $\mathcal{H}(z|x)$ はそれぞれシャノンエントロピーと条件付きエントロピーを示す。相互情報の効果は広く研究されており^[?, ?, ?]、脳波においても、MBrain^[?]で、 $I(x, z)$ が重要な脳波の波形の予測を行っている。

InfoNCE

実際には、特にデータが高次元で連続的な場合、相互情報の推定は不可能である^[?, ?]。そのため、通常、目的関数を評価するために近似する^[?]。Information Noise Contrastive Estimation (InfoNCE) 損失は、その目的関数としてよく用いられる^[?]：

$$\mathcal{L}_{\text{InfoNCE}} := \mathbb{E} \left[-\log \frac{\exp(\mathbf{z} \cdot \mathbf{z}^{(+)} / \tau)}{\sum_j \exp(\mathbf{z} \cdot \mathbf{z}^{(-)} / \tau)} \right], \quad (3.2)$$

ここで, $\tau > 0$ はスケーリングパラメータ^[7], $z^{(+)}$ と $z^{(-)}$ はそれぞれ正と負のサンプルである. 損失は, z がその正の変数 $z^{(+)}$ に似ていて, 他のすべての負の変数 $z^{(-)}$ とは異なるときに低い値をとる. Eq.(??) は, データセットから無作為にサンプリングされた一連の $z^{(-)}$ の中からターゲット z を識別することを指す.

事前学習とファインチューニング

自己教師あり学習は, 手動でラベル付けされたデータを必要としないが, 最終的な目標は, 自己教師ありで事前学習されたモデルを下流の分類タスクの微調整(ファインチューニング)に利用することである. 通常, 事前学習されたモデルの最終出力を用いて, ネットワーク全体をファインチューニングする.

最近の研究では, 知識伝達の間層を用いることで利益を得られることが示されており, 低リソースのターゲットタスクに最も効果的なのは, 部分的なネットワーク微調整であることが示されている^[7]. 提案する手法はこの方針に従っており, 下流タスクである状態パターン検出に有効な表現を抽出し, 計算コストを削減するための適切な中間層を見つけることを目指す.

3.0.2 問題定義

定義 1. (多変量時系列, MTS) 多変量時系列は複数のセンサーや観測対象から取得した時間的に連続した時系列データである. 各時点で複数の観測値を持ち, 数学的な定義として

$$\mathbf{X} = \{\mathbf{x}_i\}_{i=1}^T, \quad \mathbf{x}_i \in \mathbb{R}^N, \quad (3.3)$$

$\mathbf{x}_i$ は i 番目の時間ステップの観測値, パラメータ N は時系列データの次元数, T は時系列データの長さを表す. 時間ステップ i から時間ステップ j までの $\mathbf{X}$ の部分時系列を $\mathbf{X}_{i:j} \in \mathbb{R}^{N \times (j-i)}$ と表す.

定義 2. (状態パターン) 状態パターンは, 繰り返されるパターンや類似した統計的特徴を持ち, 実世界において潜在的に意味を持つ部分時系列である.

定義 3. (状態シーケンス) 多変量時系列の状態シーケンスは, 各観測点 $\mathbf{x}_i$ がどの状態パターンに属するかを示すインデックス s_i を割り当てたシーケンスである. 数学的な定義として

$$\mathbf{s} = \{s_i\}_{i=1}^T, s_i \in \mathcal{S} \quad (3.4)$$

$\mathcal{S}$ は状態パターンのインデックス集合であり, 状態シーケンスと多変量時系列は同じ長さを持つ.

本論文では状態パターンごとに部分時系列への分割可能な多変量時系列 $\mathbf{x}$ を状態パターンの数を推定し, 各観測点がどの状態パターンに属するか, 与えられた時系列 $\mathbf{x}$ に対応する状態シーケンス $\mathbf{s}$ を決定する精度の良いモデルを提案する.

表 3.1: 主な記号と定義

記号	定義
$\mathbf{X}$	時系列データストリーム
x_i	i番目の時間ステップの観測値
x'_i	周波抽出後のi番目の時間ステップの観測値
T	時系列データの長さ
N	時系列データの次元数
$\mathbf{X}_{i:j}$	時間ステップ <i>i</i> から時間ステップ <i>j</i> の $\mathbf{X}$ の部分時系列
tc	トレンド成分
sc	季節性成分
x''_i	トレンド成分と季節性成分を結合したi番目の時間ステップの値
$\mathbf{S}$	状態シーケンス
s_i	i番目の時間ステップの状態インデックス
$\mathbf{Z}$	特徴空間で表現された時系列データストリーム
z_i	i番目の時間ステップの潜在値

表3.1に主な記号と定義を示す.

第4章 提案手法

本章では，提案モデルについて述べる．提案手法では訓練フェーズと検出フェーズの2つのフェーズから構成される．訓練フェーズでは生の時系列データから区別可能な表現を学習するためにエンコーダを学習する．検出フェーズでは学習したエンコードを用いて時系列データを特徴空間に埋め込み表現として変換し，クラスタリングの結果をもとにラベルを割り当て，元の時間点に対しても対応してラベルを付与する．




図 4.1: データ拡張の概要図

時系列データストリームを高速フーリエ変換で周波数領域に変換し，低周波成分抽出を行い，逆フーリエ変換を行って時間領域に変換する．これによってノイズ成分が除去され，時系列が滑らかとなり，ノイズによる局所的なパターンの誤検出を抑制している．

4.0.1 ノイズ除去

高周波数および低周波数のノイズを効果的に除去し，全体的なデータ表現を向上させるために，すべての次元にわたる累積エネルギーに基づき，周波数領域からアクティブな周波数を動的に選択して保持する．信号処理におけるエネルギーは信号の周波数成分の強度を定量化し，低エネルギーは強度と活性の低下を示すことや，ノイズが極端な周波数に集中しやすく，アクティブ周波数は中央範囲に集中する傾向がある．ノイズを除去する過程で重要な情報が欠落しないように連続的な周波数帯域を選択してノイズの除去を行う．高速フーリエ変換(FFT)で時系列データを周波数領域に変換し，低周波成分の抽出を行う．そ

の後逆FFTを行なって時間領域に戻し、振幅が周波数の数でスケールされるため正規化処理を行う。

$$x'(t) = \text{IRFFT} \left(\begin{cases} \text{FFT}(x), & f \leq \text{trade_off_freq} \\ 0, & f > \text{trade_off_freq} \end{cases} \right) \cdot \frac{\text{trade_off_freq}}{T} \quad (4.1)$$

trade_off_freq は低周波数のカットオフ点、 T は時系列の長さを表す。

4.0.2 成分分解

時系列データは長期的に変動する要素であるトレンド、一定の時間で周期的に変動する要素である季節性、ノイズ成分に分割することでデータの特徴を把握しやすくなる。移動平均を用いてデータをトレンド成分と季節成分に分割する。

- **トレンド成分 (tc):** トレンド成分 $tc \in \mathbb{R}^{N \times P'}$ は、サイズ κ (奇数) の移動平均カーネルを使用して計算する。

$$tc[n, t] = \frac{1}{\kappa} \sum_{i=-(\kappa-1)/2}^{(\kappa-1)/2} x'[n, t + i]. \quad (4.2)$$

- **季節性成分 (sc):** 季節性成分 $sc \in \mathbb{R}^{N \times P'}$ は、トレンド成分 tc を x' からの差で表す。

$$sc = x' - tc. \quad (4.3)$$

n は次元を表すインデックス、 t は時間インデックスである。

$$x'' = \text{concat}(tc, sc) \quad (4.4)$$

トレンド成分と季節成分を次元方向で結合する。

さらにSTL(Seasonal Decomposition Of Time Series By Loess)分解を用いた方法でも成分分解を行い、精度の違いについても検証する。STL分解はローカルな多項式回帰(Loess)を適用するためトレンドと季節性を考慮してデータ全体に対して平滑化を行い、トレンドと季節成分が収束するまでLoess回帰を反復して行うため、計算コストは高いが複雑なトレンドやノイズ除去に優れた計算処理である。

Loess回帰は時系列データや散布図データの点 (x_i, y_i) に対して、局所的な多項式回帰を用いて滑らかな関数 $\hat{f}(x)$ を推定することである。

$$y_i = f(x_i) + \varepsilon_i \quad (4.5)$$

$$\hat{y}_i = \hat{f}(x_i) \quad (4.6)$$

ここで y_i は観測値, $f(x)$ は未知の真の関数, ε_i は誤差項, $\hat{f}(x_i)$ は推定された平滑化関数である. 推定するために各データポイント x_0 について, 近傍のデータ点 (x_i, y_i) に対して重み付き最小二乗法を適用し、局所的な多項式回帰を行い線形回帰（1次）の回帰関数は：

$$\hat{f}(x) = \beta_0 + \beta_1 x \quad (4.7)$$

2次多項式回帰の回帰関数は：

$$\hat{f}(x) = \beta_0 + \beta_1 x + \beta_2 x^2 \quad (4.8)$$

と表され, 各点 x_0 の近傍で行うのが Loess の特徴である. Loess 回帰では, 各データポイントに異なる重み w_i を付けた最小二乗法を使用し

$$\sum_i w_i (y_i - \hat{f}(x_i))^2 \quad (4.9)$$

この誤差関数を最小化することで, 係数 $\beta_0, \beta_1, \beta_2$ を求めることとなる. さらに各データ点の影響度を決定するために, トライキューレイ (tricube kernel) が一般的に使用される.

$$w_i = \left(1 - \left(\frac{|x_i - x_0|}{d}\right)^3\right)^3, \quad |x_i - x_0| < d \quad (4.10)$$

d はスムージングの範囲（スパン）, x_i が x_0 に近いほど w_i が大きくなり, x_i が x_0 から離れると $w_i \rightarrow 0$ になる. すべてのデータ点 x_0 に対してこの操作を繰り返すことでスムーズな回帰曲線 $\hat{f}(x)$ が得られ, トレンドと季節成分, ノイズ成分に分解される.

4.0.3 デュアル学習

本提案手法では, 大域的なパターン情報と局所的なパターン情報を学習するために時系列データ全体に対する機構とスライディングウィンドウ処理を行い部分系列に対する機構の二つを用いてデュアル学習を行う. トレンド成分と季節成分のそれぞれに適応する.

大域的パターン抽出

時系列データ全体を使用し, 時系列データの中で各観測点がどのような特徴を持っているかを特徴空間に投射するように学習するモジュールである. 時系列データをベクトル表現に変換する TS2Vec を改良したものである. 入力時系列に対してランダムクロッピングを行い, 学習データの多様性を学習する. 入力時系列 $x'' \in \mathbb{R}^{T \times N}$ に対して2つのランダムなセグメント $[a_1, b_1]$ および $[a_2, b_2]$ を抽出する:

$$0 < a_1 \leq a_2 \leq b_1 \leq b_2 \leq T \quad (4.11)$$

この時に大域的な情報を得るために以下の制約を加える.

$$b_1 - a_2 \geq T \cdot \gamma \quad (4.12)$$

γ は使用する時系列長であり, 本研究では0.8に設定している. $\mathbf{x}''_{a_1:a_2}$, $\mathbf{x}''_{b_1:b_2}$ に対して前結合層で高次元の潜在表現 $\mathbf{z}_{1_{a_1:a_2}}$, $\mathbf{z}_{2_{b_1:b_2}}$ に変換する. オーバーラップする部分時系列の[a2,b1]の潜在表現は一貫性があるように学習するため, 対照学習の正のペアとして設定する. 異なる時刻や各次元の特徴を学習できるように異なる観測点や異なる時系列を負のペアとして設定する.

i番目の時系列における観測点tの時間的な対照損失:

$$\ell_{\text{temp}}^{(i,t)} = -\log \frac{\exp(r_{i,t} \cdot r'_{i,t})}{\sum_{t' \in \Omega} \exp(r_{i,t} \cdot r'_{i,t'}) + \sum_{t' \neq t} \exp(r_{i,t} \cdot r_{i,t'})} \quad (4.13)$$

i番目の時系列における観測点tの各次元間の対照損失:

$$\ell_{\text{inst}}^{(i,t)} = -\log \frac{\exp(r_{i,t} \cdot r'_{i,t})}{\sum_{j=1}^B \exp(r_{i,t} \cdot r'_{j,t}) + \sum_{j \neq i} \exp(r_{i,t} \cdot r_{j,t})} \quad (4.14)$$

さらに各観測点は時間的に連続であるため, 時間的に近い観測点の特徴空間で近くする平滑さの損失:

$$\ell_{\text{smooth}}^{(i,t)} = (X[t+1, n] - X[t, n])^2 \quad (4.15)$$

時間的な損失は動的なパターン変化を捉え, 各次元間の損失は各次元の固有の特性を捉え, 特徴空間上で時間的な意味を捉える平滑損失の輪として, 大域的な損失は次のように定義される.

$$\mathcal{L}_{\text{global}} = \frac{1}{NT} \sum_i \sum_t \left(\ell_{\text{temp}}^{(i,t)} + \ell_{\text{inst}}^{(i,t)} + \ell_{\text{smooth}}^{(i,t)} \right) \quad (4.16)$$

局所的パターン抽出

設定されたウィンドウサイズとステップ幅をもとに元の時系列データをスライディングウィンドウ処理をする. これにより時系列の分割し, 部分時系列として局所的な特徴を捉える.

$$\text{ウィンドウの個数} = \left\lfloor \frac{\text{時系列の長さ} - \text{ウィンドウサイズ}}{\text{ステップ幅}} \right\rfloor + 1 \quad (4.17)$$

各ウィンドウごとに平均値, 分布やデータの変動を表す標準偏差, 周期性の強さや安定性を表すスペクトルエネルギー, 主要なデータ周期を表す主要周波数成分の4つの統計的特徴量を算出する. この後, 基準となるウィンドウに対して統計的特徴量が近いウィンドウを正のペア, 遠いウィンドウを負のペアとして設定し, 時間的に離れた局所的なパターンを同一の状態パターンであると学習するように促進している. 基準となるウィンドウは一様分布からランダムに抽出される.




図 4.2: 局所的パターン抽出の概要図：時系列をスライディングウィンドウで分割し、それぞれで統計的特徴量を計算し、近いものを正のペアに、遠いものを負のペアにしてそれぞれ $\mathcal{L}_{positive}$, $\mathcal{L}_{negative}$ を計算し、局所的なパターンを学習する。

$$\mathcal{L}_{positive} = \frac{2}{M \cdot v} \sum_{k=1}^M \sum_{j=1}^v -\log(\sigma(f_{\theta}(o_i)^{\top} f_{\theta}(o_j))) \quad (4.18)$$

$$\mathcal{L}_{negative} = \frac{2}{M \cdot v} \sum_{k=1}^M \sum_{j=1}^v -\log(\sigma(-f_{\theta}(o_i)^{\top} f_{\theta}(o_k))) \quad (4.19)$$

$$\mathcal{L}_{local} = \mathcal{L}_{positive} + \mathcal{L}_{negative} \quad (4.20)$$

o_i は基準となるウィンドウ, o_j は正のペアウィンドウ, o_k は負のペアウィンドウである. 特徴表現へ変換した各ウィンドウの類似性は内積で計算される.

最終的にデュアル学習の損失関数は以下ようになる.

$$\mathcal{L}_{\text{dual}} = \mathcal{L}_{\text{global}} + \mathcal{L}_{\text{local}} \quad (4.21)$$

4.0.4 状態パターン検出アルゴリズム

局所パターン抽出と同様に時系列データをスライディングウィンドウで部分時系列として分割した後, 学習されたエンコーダを用いて特徴空間に変換し, 低次元の特徴空間内で状態パターンのクラスタ構造を識別し, 元の観測点にクラスタリングラベルを割り当てる. 各観測点は複数のラベルを受け取るため, 最終的に各観測点に割り当てられるラベルは, 最多で割り当てられたラベルに基づいて決定され, 潜在的に誤ったポイントラベルの少数を排除することができる.

提案モデルの全体図を図4.3に示す.




図 4.3: 検出アルゴリズムの概要図：時系列をスライディングウィンドウで分割してエンコーダによって特徴表現に変換した後、クラスタリングを行い、各ウィンドウに検出した状態インデックス割り当てを行う。その後各観測点に複数の状態インデックス割り当てが行われているため、最多のインデックスを最終的な状態パターンとする。

第5章 評価実験

本論文では，提案手法の有効性を検証するため，実データを用いた実験を行った．本章では以下の項目について検証する．

Q1 状態シーケンスの推定に対する提案手法の有効性

Q2 提案手法のロス関数設計の有効性

Q3 提案手法の特徴空間におけるパターン情報保持の有効性

5.0.1 実験設定

データセット

提案手法の有効性を検証するために，5つの実世界のデータセットと1つの合成データセットで実験する．これらのデータセットの統計情報は表1に示す．人間の日常動作，運動スポーツ動作，医療や昆虫の監視，電力需要データなど様々な実世界の状態を表すデータセットを選択した．なお，時系列の変化点検出の評価実験に使用されるいくつかのデータセットは状態検出に必要な各観測における状態ラベル情報が欠如しているため，部分時系列のセグメンテーションの評価には適していない．

表 5.1: データセット詳細

データセット	状態数	次元数	データ長 (k)	データ数	分割数	各状態長 (k)
合成データ	5	4	9.3~23.7	100	18~28	0.1~3.9
MoCap	4~8	4	4.6~10.6	9	6~11	0.4~2.0
ActRecTut	6	10	31.4~32.6	2	42	0.02~5.1
PAMAP2	11	9	253~408	10	18~25	2.0~40.3
USC-HAD	12	6	25.4~56.3	70	12	0.6~13.5
UCR-SEG	2~3	1	2~40	32	2~3	1~25

- 合成データ：TSAGen[37]というツールを使用し，各々にランダムな時間幅を持つ5つの状態が遷移する合成時系列を生成した．

表 5.2: Overall comparison.

Method	Synthetic		MoCap		ActRecTut		PAMAP2		UscHad	
	ARI	NMI	ARI	NMI	ARI	NMI	ARI	NMI	ARI	NMI
HVGH [29]	0.0809	0.1606	0.0900	0.1523	0.0881	0.2088	0.0032	0.0374	0.0788	0.1883
HDP.HSMM [38]	0.6619	0.7798	0.5509	0.7230	0.6644	0.6473	0.2882	0.5338	0.4678	0.6839
TICC [21]	0.6242	0.7481	0.7218	0.7524	0.7839	0.7466	0.3008	0.5955	0.3947	0.7028
AutoPlait [28]	0.0713	0.1307	0.8057	0.8289	0.0586	0.1148	N/A	N/A	0.2948	0.5413
ClasPTS.KMeans [16]	0.2950	0.4480	0.5450	0.6763	0.2825	0.2309	0.1700	0.5830	0.5075	0.6940
TS2Vec [41]	0.8176	0.8407	0.7529	0.7584	0.7670	0.7407	0.3135	0.5905	0.6522	0.8126
Time2State	0.8843	0.8025	0.7896	0.7812	0.7909	0.7473	0.3345	0.6143	0.6833	0.8164
Proposed(Ours)	0.8802	0.8731	0.7603	0.7753	0.6144	0.6376	0.3090	0.5702	0.7804	0.8671

表 5.3: ablation study.

Method	ノイズ除去モジュール I/O	成分分割モジュール I/O	局所的な学習モジュール I/O	大域的な学習モジュール I/O	スライディングウィンドウ I/O
NMI	0.0809	0.1606	0.0900	0.1523	0.0881

- MoCap: CMU モーションキャプチャデータセットであり, 歩行, 走行, 跳躍, ダンスなどの状態ラベルが付与されている. [23] の設定に従い, 左/右の腕と脚に対応する4次元を選択した.
- ActRecTut: スポーツ活動から収集された加速度データが含まれ, 実験では人々のウォーキングに関連するデータのサブセットを使用する. このデータは潜在状態推論ではなく頻出パターンのマイニングのためのものであり, 他の活動に対する十分なラベル付きデータは含まれていない.
- PAMAP2: 8人が実施した歩行や着席などの24の低レベルおよびサッカー動作などの高レベルの人間活動が含まれている. 手, 胸, 足首のx, y, z軸の加速度データに対応する9次元を選択した.
- USC-HAD: 14人の人々が個別に記録した走行や跳躍などの12の人間活動が含まれている. 右腰の前に装着した3軸加速度計と3軸ジャイロメータから100Hzでサンプリングされている.
- UCR-SEG: 医療、昆虫、ロボット、電力需要などから取得した単変量時系列のベンチマークデータセットである.

各データセットは平均値と分散で正規化(z-normalization)して使用した.




図 5.1: Mocap データセットの 4 次元の時系列データに対して学習の段階である 5epoch, 25epoch, 50epoch において UMAP を用いた特徴空間の可視化を行なった. epoch が進むにつれて各クラスの混合度合いが小さくなっている.

比較手法

有効性を検証するために、以下の比較手法と比較を行った.

- AutoPlait: 最小記述長原理を適用して MTS をセグメント化し、パラメータ調整やユーザーの介入なしに各セグメントを隠れマルコフモデルで再帰的にモデリングする.
- HVGH: 多変量時系列 (MTS) ウィンドウのエンコードに変分オートエンコーダを使用し、クラスタリングには階層ディリクレプロセス (HDP) を利用し状態の数を自動的に推定する.
- TICC: 実験で使用した唯一の状態の数を指定する必要がある手法であり、相関ネットワークをエンコードにし、トリプレット逆共分散に基づいてクラスタリングを行う.
- HDP-HSMM: 従来の隠れセミマルコフモデルを拡張したベイズ非パラメトリック手法であり、HDP で状態の数を推定する.
- ClaSP+TSKMeans: 複数のバイナリ分類器を使用して MTS の変化点を特定し、KMeans でクラスタリングを行う. 簡単のために本論文の残りの部分ではこの ClaSP+TSKMeans を単に ClaSP と呼ぶこととする.
- Ts2Vec: 階層型の対照学習によって、任意の意味レベルでの時系列の表現を学習し、クラスタリングには DPGMM を利用し状態の数を自動的に推定する.
- Time2State: MTS ウィンドウのエンコードに時系列畳み込みネットワークを使用し、クラスタリングには DPGMM を利用し状態の数を自動的に推定する.

評価指標

検出精度を評価するために、調整ランド指数（ARI）と正規化相互情報量（NMI）を使用する。ARIは予測クラスタと真のクラスタ間の一致度を定量化し、クラスタリングの細かさを強調する一方、NMIは真のクラスタリングとモデルクラスタリング間の共有情報を測定する。

$$ARI = \frac{\text{Observed Index} - \text{Expected Index}}{\text{Max Index} - \text{Expected Index}} \quad (5.1)$$

Observed Indexは推定したクラスタ分割と正解データとの一致数、Expected Indexはランダムなクラスタ分割と正解データとの一致数、Max Indexは理論的に達成可能な正解データとの一致数である。

$$NMI(U, V) = \frac{2 \cdot I(U; V)}{H(U) + H(V)} \quad (5.2)$$

Uは正解ラベル、Vは予想クラスタであり、 $I(U; V)$ はどれだけ情報を共有しているかを示す相互情報量、 $H(U)$ と $H(V)$ は分布の不確定性を示すエントロピーである。 $I(U; V)$ を $H(U)$ と $H(V)$ で割る正規化を行い、比較の公平性を確保している。

実験環境の詳細

全ての実験は512GBのメモリ、Xeon Gold 6258R 2.7GHz の28コアCPUおよび RTX A6000 48GB GPUを搭載したLinuxマシン上で実施した。

ハイパーパラメータの最適化

公平な比較のため、AutoPlaitを除くすべてのベースラインのパラメータを最適化する。AutoPlaitはユーザーの介入やパラメータ調整を必要としない[23]。データセットごとのパラメータ調整は可能であるが、すべての時系列ごとのパラメータ調整は困難であるため、元の論文で提供された戦略と推奨事項に基づいてハイパーパラメータを選択する。推奨事項がない場合は適切なハイパーパラメータ空間でグリッドサーチを行った。提案手法のパラメータ最適化ははるかに疎な空間で行われ、ウィンドウサイズとステップサイズをそれぞれ128, 256, 512および25, 50, 75, 100で共同最適化を行なった。クラスタリング手法については、DBSCAN, MeanShift, DPGMMの中で最も精度が良い結果を記載している。

5.0.2 Q1：状態シーケンスの推定に対する提案手法の有効性

提案手法とベースライン手法の6つのデータセットにわたる全体比較を表1に示す。提案手法は、ARIとNMIのスコアでどのデータセットに対しても一貫して高精度な結果を達成

している. Autoplaitは最短の平均MTS長を持つMoCapデータセットで優れており、最高のARIおよびNMIスコアを達成しているが、処理時間は長く、特に最長の平均MTS長を持つPAMAP2データセットを処理できない点が問題となっている. ClaSPTS_KMeansは、単変量のUcrSegデータセットで最高のARIおよびNMIスコアを達成していますが、他のMTSデータセットでは競争力がない. 提案手法はノイズ除去のモジュールを取り入れているため、ノイズに強く、ノイズ成分がはっきりとしている合成データセットに対して、最高のARIおよびNMIスコアを達成している.

5.0.3 Q2：提案手法のロス関数設計の有効性

案されたコンポーネントの有効性と効率性を評価するため、アブレーションスタディを行う. ノイズ除去のモジュール、成分分割のモジュール、局所的な学習モジュール、大域的な学習モジュールをそれぞれ使わずに精度検証をしたほか、スライディングウィンドウによる状態パターン検出アルゴリズムの代わりに全体の時系列データに関して一括でエンコーディングを行い、状態パターン検出を行った時の精度を表4に示す. Mocapデータにおける実験結果のみを抜粋する.

5.0.4 Q3：提案手法の特徴空間におけるパターン情報保持の有効性

学習エポックを進めるごとに状態パターンが検出しやすいように特徴空間を可視化するために次元削減の手法の一つであるUMAPを用いて高次元データである特徴空間を高次元データを低次元空間に投射した. 他の手法と比べてデータの局所的な構造と大域的な構造の両方を学習に優れたいる. ここでは5epoch, 25epoch, 50epochごとに特徴空間の可視化を行なったところ、5epochではクラスタ構造が不明瞭であったが、25,50epochに学習が進むと他の色との混合度合いが小さくなり、それぞれの状態ごとにクラスタ構造を取り、特徴空間において視覚的なパターン情報を持つようになっていることが確認された.

5.0.5 追加実験

状態数未知の場合と状態数既知の場合の精度比較

スライディングウィンドウ処理と一括クラスタリングの精度比較

第6章 むすび

本論文では、大域的な情報と局所的な情報を活用する自己教師あり対照学習に基づく時系列セグメンテーション手法を提案した。提案手法は冒頭で確認した以下の優れている特性を全て達成している。

- 状態パターン数が未知の様々なデータに対して、適切なパターン数が学習してパターン検出を行い、適切なパターン数の検出が可能である。
- データの長さに依存することなく、様々なデータに対して実用的なパターン検出が可能である。
- 対照学習の重要な設計である組み合わせにおいて、バイアスを軽減する対照学習における正負の組み合わせを提案した。
- 時間領域と周波数領域に対するデータ拡張によってノイズ除去を行い、ノイズに強く、局所的な情報と大域的な情報の両方を捉える手法であり、従来の手法に対する優位性を実証した。

今後は検出した状態パターンに基づいて、行動予測や故障予測など、予測タスクに応用し、パターンに基づく使用者が理解しやすい予測アルゴリズムを研究する予定である。

謝辞

本研究を進めるにあたり，多くの方々から厚いご指導ご鞭撻を賜りました．

研究への多大なご指導と研究に専念できる整った環境のご支援を頂いた大阪大学産業科学研究所櫻井保志教授，松原靖子准教授に心から感謝の意を表し厚く御礼申し上げます．また，研究への取り組み方に関して数多くのご助言を頂いた井関隆之特任教授，川畑光希助教，木村輔特任助教に深謝の意を表します．

実験データの解析や整理に関して産業的な観点から数々のご助言，ご協力を頂いた小松製作所の佐藤正彦様，水谷雅巳様に心から感謝申し上げます．研究の方向性，実験のアプローチ，実験環境の構築，さらには各種ツール・ソフトウェアの利用に関してまで多大なご教授を頂きました光岡孝テクニカルマネージャーに深く御礼申し上げます．そして，日々の議論から論文の添削まで多大なサポートを頂きました櫻井研究室，産業科学研究所AIセンターのみなさまに心から感謝の意を示します．

最後に，これまで学生生活や課外活動を支え，応援していただいた家族に心から感謝申し上げます．

参考文献

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In Isabelle Guyon, Ulrike von Luxburg, Samy Bengio, Hanna M. Wallach, Rob Fergus, S. V. N. Vishwanathan, and Roman Garnett, editors, *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA*, pages 5998–6008, 2017.
- [2] Yasuko Matsubara, Yasushi Sakurai, and Christos Faloutsos. Autoplait: automatic mining of co-evolving time sequences. In Curtis E. Dyreson, Feifei Li, and M. Tamer Özsu, editors, *International Conference on Management of Data, SIGMOD 2014, Snowbird, UT, USA, June 22-27, 2014*, pages 193–204. ACM, 2014.
- [3] Yasuko Matsubara and Yasushi Sakurai. Regime shifts in streams: Real-time forecasting of co-evolving time sequences. In Balaji Krishnapuram, Mohak Shah, Alexander J. Smola, Charu C. Aggarwal, Dou Shen, and Rajeev Rastogi, editors, *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, CA, USA, August 13-17, 2016*, pages 1045–1054. ACM, 2016.
- [4] Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting. *Advances in neural information processing systems*, 34:22419–22430, 2021.
- [5] Yong Liu, Haixu Wu, Jianmin Wang, and Mingsheng Long. Non-stationary transformers: Exploring the stationarity in time series forecasting. *Advances in Neural Information Processing Systems*, 35:9881–9893, 2022.
- [6] Shengsheng Lin, Weiwei Lin, Xinyi Hu, Wentai Wu, Ruichao Mo, and Haocheng Zhong. Cyclenet: enhancing time series forecasting through modeling periodic patterns. *arXiv preprint arXiv:2409.18479*, 2024.
- [7] Shohreh Deldari, Daniel V Smith, Amin Sadri, and Flora Salim. Espresso: Entropy and shape aware time-series segmentation for processing heterogeneous sensor data. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 4(3):1–24, 2020.

- [8] David Hallac, Sagar Vare, Stephen Boyd, and Jure Leskovec. Toeplitz inverse covariance-based clustering of multivariate time series data. In *Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining*, pages 215–223, 2017.
- [9] Minji Lee, Heon-Gyu Kwak, Hyeong-Jin Kim, Dong-Ok Won, and Seong-Whan Lee. Se-riessleepnet: an eeg time series model with partial data augmentation for automatic sleep stage scoring. *Frontiers in Physiology*, 14:1188678, 2023.
- [10] Stéfano Frizzo Stefenon, Matheus Henrique Dal Molin Ribeiro, Ademir Nied, Kin-Choong Yow, Viviana Cocco Mariani, Leandro dos Santos Coelho, and Laio Oriel Seman. Time series forecasting using ensemble learning methods for emergency prevention in hydroelectric power plants with dam. *Electric Power Systems Research*, 202:107584, 2022.
- [11] Kouki Kawabata, Yasuko Matsubara, and Yasushi Sakurai. Streamscope: Automatic pattern discovery over data streams. *Proceedings of the First International Workshop on Exploiting Artificial Intelligence Techniques for Data Management*, 2018.
- [12] Yasuko Matsubara, Yasushi Sakurai, and Christos Faloutsos. Autoplait: automatic mining of co-evolving time sequences. In Curtis E. Dyreson, Feifei Li, and M. Tamer Özsu, editors, *International Conference on Management of Data, SIGMOD 2014, Snowbird, UT, USA, June 22-27, 2014*, pages 193–204. ACM, 2014.
- [13] Dimitri Palaz, Mathew Magimai-Doss, and Ronan Collobert. End-to-end acoustic modeling using convolutional neural networks for hmm-based automatic speech recognition. *Speech Commun.*, 108:15–32, 2019.
- [14] Talal Almutiri and Farrukh Nadeem. Markov models applications in natural language processing: A survey. *Int. J. Inf. Technol. Comput. Sci.*, 2:1–16, 2022.
- [15] David E Rumelhart, Geoffrey E Hinton, and Ronald J Williams. Learning representations by back-propagating errors. *nature*, 323(6088):533–536, 1986.
- [16] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
- [17] Kyunghyun Cho, Bart van Merriënboer, Çağlar Gülçehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using RNN encoder-decoder for statistical machine translation. In Alessandro Moschitti, Bo Pang, and Walter Daelemans, editors, *Proceedings of the 2014 Conference on Empirical Methods in*

- Natural Language Processing, EMNLP 2014, October 25-29, 2014, Doha, Qatar, A meeting of SIGDAT, a Special Interest Group of the ACL*, pages 1724–1734. ACL, 2014.
- [18] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. In Yoshua Bengio and Yann LeCun, editors, *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*, 2015.
 - [19] Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting. In Marc’Aurelio Ranzato, Alina Beygelzimer, Yann N. Dauphin, Percy Liang, and Jennifer Wortman Vaughan, editors, *Advances in Neural Information Processing Systems 34: Annual Conference on Neural Information Processing Systems 2021, NeurIPS 2021, December 6-14, 2021, virtual*, pages 22419–22430, 2021.
 - [20] Haoyi Zhou, Shanghang Zhang, Jieqi Peng, Shuai Zhang, Jianxin Li, Hui Xiong, and Wancai Zhang. Informer: Beyond efficient transformer for long sequence time-series forecasting. In *Thirty-Fifth AAAI Conference on Artificial Intelligence, AAAI 2021, Thirty-Third Conference on Innovative Applications of Artificial Intelligence, IAAI 2021, The Eleventh Symposium on Educational Advances in Artificial Intelligence, EAAI 2021, Virtual Event, February 2-9, 2021*, pages 11106–11115. AAAI Press, 2021.
 - [21] Tian Zhou, Ziqing Ma, Qingsong Wen, Xue Wang, Liang Sun, and Rong Jin. Fedformer: Frequency enhanced decomposed transformer for long-term series forecasting. In Kamalika Chaudhuri, Stefanie Jegelka, Le Song, Csaba Szepesvári, Gang Niu, and Sivan Sabato, editors, *International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, Maryland, USA*, volume 162 of *Proceedings of Machine Learning Research*, pages 27268–27286. PMLR, 2022.
 - [22] Shizhan Liu, Hang Yu, Cong Liao, Jianguo Li, Weiyao Lin, Alex X. Liu, and Schahram Dustdar. Pyraformer: Low-complexity pyramidal attention for long-range time series modeling and forecasting. In *The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022*. OpenReview.net, 2022.
 - [23] Yasuko Matsubara and Yasushi Sakurai. Dynamic modeling and forecasting of time-evolving data streams. In Ankur Teredesai, Vipin Kumar, Ying Li, Rómer Rosales, Evimaria Terzi, and George Karypis, editors, *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD 2019, Anchorage, AK, USA, August 4-8, 2019*, pages 458–468. ACM, 2019.

- [24] Takato Honda, Yasuko Matsubara, Ryo Neyama, Mutsumi Abe, and Yasushi Sakurai. Multi-aspect mining of complex sensor sequences. In Jianyong Wang, Kyuseok Shim, and Xindong Wu, editors, *2019 IEEE International Conference on Data Mining, ICDM 2019, Beijing, China, November 8-11, 2019*, pages 299–308. IEEE, 2019.